PHÂN BỐ NHÃN CHEXPERT SAU TIỀN XỬ LÝ DỮ LIỆU MIMIC-CXR

Số nghiên cứu Positive, Negative, Uncertain theo từng lớp trên các tập train, test, val

Bộ chia full_allviews_v2, số liệu đếm ngày 02/11/2026

TÓM TẮT

Tài liệu này trình bày số nghiên cứu (study) mang nhãn Positive (P), Negative (N) và Uncertain (U) của 14 lớp CheXpert trên ba tập train, test và val sau khi tiền xử lý dữ liệu MIMIC-CXR. Số liệu được đếm theo hai cách: theo nhãn gốc, trong đó ô trống không được tính, và theo cách mô hình được huấn luyện, trong đó ô trống được coi là Negative.

CHƯƠNG 1. DỮ LIỆU VÀ CÁCH ĐẾM

1.1. Nguồn dữ liệu

Số liệu được ghép từ hai nguồn. Thứ nhất là file nhãn CheXpert gốc của MIMIC-CXR-JPG (mimic-cxr-2.0.0-chexpert.csv.gz), mỗi dòng là một nghiên cứu với 14 cột nhãn, trong đó giá trị 1 là Positive, 0 là Negative, -1 là Uncertain và ô trống nghĩa là báo cáo không nhắc tới bệnh đó. Thứ hai là ba file chia tập sau tiền xử lý train.csv, val.csv và test.csv của bộ chia full_allviews_v2, cũng là các file mô hình đọc khi huấn luyện. Bộ chia này giữ nguyên phân chia chính thức của MIMIC-CXR và giữ mọi góc chụp.

1.2. Cách đếm

Việc đếm thực hiện ở mức nghiên cứu: mỗi nghiên cứu chỉ được tính một lần dù có nhiều ảnh. Danh sách nghiên cứu của từng tập được nối với file nhãn theo mã bệnh nhân và mã nghiên cứu, sau đó nhãn được chuyển đổi đúng như khi huấn luyện, bằng cùng một hàm của mã nguồn. Tập train có 222.758 nghiên cứu, tập val có 1.808 và tập test có 3.269. Trong đó lần lượt 2.379, 22 và 21 nghiên cứu không có thông tin CheXpert, do không có bản ghi nhãn hoặc có bản ghi nhưng cả 14 ô đều trống. Các nghiên cứu này không được tính vào bất kỳ ô nào của hai bảng dưới đây, nên số nghiên cứu có nhãn là 220.379 ở train, 1.786 ở val và 3.248 ở test.

CHƯƠNG 2. PHÂN BỐ NHÃN

2.1. Theo nhãn gốc

Bảng 2.1 đếm nhãn đúng như file CheXpert ghi, ô trống không được tính. Đây là cùng cách đếm với bảng thống kê nhãn trong bài báo META-CXR: lớp No Finding chỉ có Positive vì công cụ gán nhãn không bao giờ ghi Negative cho lớp này.

Bảng 2.1. *Số nghiên cứu theo nhãn gốc, ô trống không tính*

Lớp	Train P	Train N	Train U	Test P	Test N	Test U	Val P	Val N	Val U
Atelectasis	44.718	1.502	10.041	731	20	191	359	9	95
Cardiomegaly	43.602	15.613	5.869	866	174	115	377	124	59
Consolidation	10.476	7.817	4.186	220	95	97	82	55	48
Edema	26.093	25.133	12.777	683	305	289	242	203	108
Enlarged Cardio	6.968	5.168	9.083	151	64	204	60	51	88
Fracture	4.283	877	548	89	3	4	18	6	3
Lung Lesion	6.091	841	1.114	123	14	18	70	7	9
Lung Opacity	50.099	2.993	3.726	1.038	58	79	388	18	26
No Finding	74.305	0	0	568	0	0	582	0	0
Pleural Effusion	52.759	26.615	5.639	1.074	340	130	467	203	45
Pleural Other	1.933	126	743	63	0	16	15	0	6
Pneumonia	16.093	23.904	17.797	335	268	350	128	166	144
Pneumothorax	10.171	41.271	1.106	112	727	19	75	358	9
Support Devices	64.868	3.422	230	1.125	34	4	565	30	3

P: Positive, N: Negative, U: Uncertain. Đếm ở mức nghiên cứu.

2.2. Khi ô trống được coi là Negative

Bảng 2.2 đếm theo cách mô hình hiện tại được huấn luyện, tương ứng với thiết lập blank_label_policy bằng negative, giống cách bài báo gốc xử lý giá trị thiếu. Các cột P và U giữ nguyên như Bảng 2.1; chỉ cột N tăng lên vì mọi ô trống của nghiên cứu có thông tin CheXpert được tính là Negative. Khi đó Negative là lớp đông nhất ở mọi bệnh, và No Finding có 146.074 nghiên cứu Negative trên tập train.

Bảng 2.2. *Số nghiên cứu khi ô trống được coi là Negative*

Lớp	Train P	Train N	Train U	Test P	Test N	Test U	Val P	Val N	Val U
Atelectasis	44.718	165.620	10.041	731	2.326	191	359	1.332	95
Cardiomegaly	43.602	170.908	5.869	866	2.267	115	377	1.350	59
Consolidation	10.476	205.717	4.186	220	2.931	97	82	1.656	48
Edema	26.093	181.509	12.777	683	2.276	289	242	1.436	108
Enlarged Cardio	6.968	204.328	9.083	151	2.893	204	60	1.638	88
Fracture	4.283	215.548	548	89	3.155	4	18	1.765	3
Lung Lesion	6.091	213.174	1.114	123	3.107	18	70	1.707	9
Lung Opacity	50.099	166.554	3.726	1.038	2.131	79	388	1.372	26
No Finding	74.305	146.074	0	568	2.680	0	582	1.204	0
Pleural Effusion	52.759	161.981	5.639	1.074	2.044	130	467	1.274	45
Pleural Other	1.933	217.703	743	63	3.169	16	15	1.765	6
Pneumonia	16.093	186.489	17.797	335	2.563	350	128	1.514	144
Pneumothorax	10.171	209.102	1.106	112	3.117	19	75	1.702	9
Support Devices	64.868	155.281	230	1.125	2.119	4	565	1.218	3

P: Positive, N: Negative, U: Uncertain. Đây là phân bố nhãn mô hình thực sự học.

CHƯƠNG 3. SO SÁNH VỚI BẢNG CỦA BÀI BÁO

Số liệu của chúng tôi không trùng với bảng thống kê nhãn trong bài báo META-CXR, và ở nhiều dòng hai cột N và U của bài báo dường như bị đổi chỗ. Chẳng hạn với Atelectasis trên tập train, bài báo ghi N bằng 10.759 và U bằng 1.579, còn chúng tôi đếm được N bằng 1.502 và U bằng 10.041. Với Pneumothorax trên tập train, bài báo ghi U bằng 44.292, gần với số Negative chúng tôi đếm được là 41.271, trong khi số Uncertain của chúng tôi chỉ là 1.106. Đây là nhận xét rút ra từ việc so sánh hai bảng, chưa được tác giả xác nhận; số của bài báo được chép lại từ ảnh bảng và chưa đối chiếu với bản PDF. Phần chênh lệch còn lại có thể do bài báo dùng phiên bản dữ liệu hoặc cách lọc khác.