CÁC ĐỘ ĐO ĐÁNH GIÁ SỬ DỤNG TRONG ĐỀ TÀI

Mô tả độ đo, cách tính và lý do lựa chọn cho hai giai đoạn của pipeline META-CXR

PHẠM VI TÀI LIỆU

Tài liệu này chỉ mô tả các độ đo mà đề tài dùng để đánh giá hai giai đoạn của pipeline: Giai đoạn 1 phân loại 14 bất thường trên ảnh X-quang ngực, và Giai đoạn 2 sinh phần FINDINGS của báo cáo. Với mỗi độ đo, tài liệu nêu đại lượng mà độ đo phản ánh, cách tính trong đề tài, lý do lựa chọn, và đối chiếu với bài báo META-CXR gốc [1]. Kết quả số chỉ được dùng khi cần minh họa lý do lựa chọn; kết quả đầy đủ nằm trong tài liệu đánh giá thực nghiệm riêng.

CHƯƠNG 1. ĐỘ ĐO CHO GIAI ĐOẠN 1: PHÂN LOẠI BẤT THƯỜNG

1.1. Cách diễn giải nhãn trước khi tính độ đo

Mỗi ô nhãn CheXpert có bốn trạng thái: dương tính, âm tính, không chắc chắn, và để trống khi báo cáo không nhắc tới bất thường đó [2]. Trên MIMIC-CXR-JPG, 79,4% số ô để trống. Vì vậy trước khi tính bất kỳ độ đo nào phải chọn câu hỏi mà độ đo trả lời, và đề tài ghi rõ lựa chọn này trong mọi tệp kết quả.

Cách thứ nhất, gọi là phân cực có che (masked polarity), bỏ qua ô trống và chỉ hỏi phân cực của bất thường khi báo cáo đã nhắc tới nó. Đây là mẫu số đúng cho hàm mất mát phân loại ba lớp, nhưng là mẫu số sai cho F1: khi chỉ xét các ô được nhắc tới, dương tính chiếm đa số ở phần lớn bất thường, nên một bộ phân loại hằng số cũng đạt F1 cao. Cách thứ hai, gọi là hiện diện trong nghiên cứu (study presence), hỏi câu hỏi lâm sàng: nghiên cứu này có bất thường X hay không; ô trống, âm tính và không chắc chắn đều được coi là không có. Cách này trùng với chính sách U-Zeros của CheXpert [2] và với cách CheXclusion dùng khi đánh giá trên MIMIC-CXR [3].

Bảng 1.1. *F1 dương tính macro của mô hình và của các bộ phân loại hằng số dưới hai cách diễn giải (tập kiểm tra, 3.269 nghiên cứu)*

Bộ phân loại	Phân cực có che	Hiện diện trong nghiên cứu
Mô hình của đề tài	0,8864	0,3542
Luôn dự đoán dương tính	0,8397	0,2280
Dự đoán lớp đa số của từng nhãn	0,8200	0,0000

Cùng một tệp dự đoán, chỉ khác cách diễn giải nhãn. Ngưỡng được hiệu chuẩn trên tập kiểm định với cùng cách diễn giải.

Dưới phân cực có che, bộ phân loại luôn dự đoán dương tính đạt 0,8397, chỉ thấp hơn mô hình 0,0468. Dưới hiện diện trong nghiên cứu, cả hai bộ phân loại hằng số rơi xuống mức thấp và khoảng cách với mô hình phản ánh đúng năng lực của mô hình. Đề tài vì vậy chỉ báo cáo F1, độ chính xác, độ nhạy và độ đặc hiệu dưới cách diễn giải hiện diện trong nghiên cứu.

Bài báo gốc coi ô trống là âm tính (mục III-A của [1]) và báo cáo độ chính xác, độ nhạy, F1 trung bình cho bài toán ba lớp dương tính, âm tính, không chắc chắn. Bài báo không nêu kiểu trung bình trong bảng kết quả chính, còn nghiên cứu cắt bỏ số token chuyên gia ghi là trung bình có trọng số (mục IV-D.4 của [1]). Vì cách diễn giải nhãn và cách lấy trung bình khác nhau, các con số F1 của hai công trình không so sánh trực tiếp được.

1.2. Diện tích dưới đường cong ROC

AUROC đo xác suất mô hình xếp một nghiên cứu có bất thường cao hơn một nghiên cứu không có bất thường, trên mọi ngưỡng quyết định [4], [5]. Đề tài tính AUROC riêng cho từng nhãn rồi báo cáo hai dạng tổng hợp. AUROC macro là trung bình AUROC của các nhãn, mỗi nhãn một trọng số như nhau, nên phản ánh khả năng phân biệt của từng bất thường kể cả bất thường hiếm. AUROC micro gộp mọi cặp nghiên cứu và nhãn vào một bảng xếp hạng chung, nên nhạy với việc điểm số của các nhãn khác nhau có cùng thang đo hay không.

Lý do chọn AUROC làm độ đo chính của Giai đoạn 1 là nó không phụ thuộc ngưỡng và không đổi khi tỉ lệ bệnh thay đổi, nên tách được năng lực phân biệt khỏi cách chọn điểm hoạt động. Việc báo cáo cả hai dạng là có chủ đích: trong thực nghiệm của đề tài, hàm mất mát phân cấp làm AUROC micro tăng có ý nghĩa thống kê (+0,0273) trong khi AUROC macro không tăng có ý nghĩa (+0,0047). Chỉ nhìn AUROC micro sẽ nhầm một cải thiện về hiệu chuẩn giữa các nhãn thành một cải thiện về khả năng phân biệt. Bài báo gốc có vẽ đường cong ROC cho từng lớp nhưng không báo cáo AUROC tổng hợp trên MIMIC-CXR.

1.3. Diện tích dưới đường cong độ chính xác và độ nhạy

AUPRC macro là trung bình diện tích dưới đường cong độ chính xác theo độ nhạy của các nhãn. Khi lớp dương tính hiếm, AUROC có thể cao dù phần lớn các dự đoán dương tính là sai, còn đường cong độ chính xác và độ nhạy phản ánh trực tiếp chi phí của các báo động giả [6]. Dưới cách diễn giải hiện diện trong nghiên cứu, tỉ lệ dương tính của các nhãn chỉ khoảng 2% đến 34%, nên AUPRC là độ đo bổ sung cần thiết cho AUROC. Giá trị tham chiếu của AUPRC với một bộ phân loại ngẫu nhiên bằng tỉ lệ dương tính của nhãn, nên AUPRC luôn được đọc cùng tỉ lệ này.

1.4. Độ chính xác, độ nhạy, F1 và độ đặc hiệu tại ngưỡng đã hiệu chuẩn

Các độ đo phụ thuộc ngưỡng mô tả điểm hoạt động thực tế khi mô hình phải đưa ra quyết định có hoặc không. Đề tài báo cáo F1 dương tính macro cùng độ chính xác và độ nhạy tương ứng, và độ đặc hiệu macro để thấy mô hình có đang đổi độ đặc hiệu lấy độ nhạy hay không. Hai điểm trong cách tính quyết định giá trị các độ đo này.

Thứ nhất, ngưỡng của từng nhãn chỉ được chọn trên tập kiểm định rồi áp dụng một lần lên tập kiểm tra. Đề tài chọn ngưỡng tối đa hóa F1 theo hướng dẫn của Lipton và cộng sự [7], nhưng thay vì đứng tại đỉnh, ngưỡng được đặt ở trung vị của vùng các ngưỡng đạt ít nhất 95% F1 cực đại, vì đỉnh trên 1.808 nghiên cứu kiểm định chịu ảnh hưởng của vài nghiên cứu tình cờ nằm quanh nó. Nhãn cần ít nhất 5 mẫu dương tính trong tập kiểm định để được hiệu chuẩn; với ngưỡng tối thiểu 20, hai nhãn hiếm bị gán ngưỡng cố định 0,5, và việc hạ ngưỡng tối thiểu xuống 5 làm F1 macro thay đổi +0,0181, khoảng tin cậy [+0,0140; +0,0227].

Thứ hai, điểm số dùng để so với ngưỡng là xác suất hiện diện, bằng xác suất bất thường được nhắc tới nhân với xác suất dương tính khi được nhắc tới. Cách chấm này tương ứng đúng với câu hỏi hiện diện trong nghiên cứu. Bài báo gốc chọn ngưỡng tại điểm trên đường cong ROC gần góc trên bên trái nhất (mục V-C của [1]), một biến thể của chỉ số Youden [8], và không nêu ngưỡng được chọn trên tập nào.

1.5. Khoảng tin cậy bootstrap ghép cặp

Mọi so sánh giữa hai cấu hình được thực hiện trên cùng một tập nghiên cứu và báo cáo kèm khoảng tin cậy 95% bằng bootstrap theo nghiên cứu [9]: mỗi lần lặp lấy mẫu có hoàn lại các nghiên cứu, tính độ đo cho cả hai cấu hình trên đúng mẫu đó, rồi lấy hiệu.

Đề tài dùng 2.000 lần lặp với hạt giống 16. Lấy mẫu ghép cặp loại bỏ phần biến thiên do độ khó của từng nghiên cứu, nên nhạy hơn nhiều so với việc so hai khoảng tin cậy độc lập. Một khác biệt chỉ được coi là có ý nghĩa khi khoảng tin cậy không chứa 0 và cận gần 0 nhất cách 0 ít nhất 0,0005; cận nằm sát 0 hơn mức này có thể đổi dấu chỉ vì nhiễu Monte Carlo. Bài báo gốc báo cáo giá trị điểm mà không kèm khoảng tin cậy.

1.6. Tóm tắt độ đo Giai đoạn 1

Bảng 1.2. *Các độ đo phân loại và đối chiếu với bài báo gốc*

Độ đo	Phản ánh	Cách tính trong đề tài	Bài báo gốc
AUROC macro	Khả năng phân biệt của từng bất thường	Hiện diện trong nghiên cứu, không cần ngưỡng	Chỉ vẽ đường cong
AUROC micro	Tính nhất quán thang điểm giữa các nhãn	Gộp mọi ô nghiên cứu và nhãn	Không báo cáo
AUPRC macro	Chi phí báo động giả khi lớp hiếm	Hiện diện trong nghiên cứu	Không báo cáo
F1, độ chính xác, độ nhạy dương tính macro	Điểm hoạt động thực tế	Ngưỡng hiệu chuẩn trên tập kiểm định	Có, cho ba lớp, ô trống là âm tính
Độ đặc hiệu macro	Cái giá của độ nhạy	Cùng ngưỡng như trên	Không báo cáo
Khoảng tin cậy ghép cặp	Mức chắc chắn của một khác biệt	Bootstrap 2.000 lần theo nghiên cứu	Không báo cáo

CHƯƠNG 2. ĐỘ ĐO CHO GIAI ĐOẠN 2: SINH BÁO CÁO

2.1. Giao thức chấm điểm

Các độ đo sinh văn bản rất nhạy với cách tách từ và với cài đặt cụ thể, nên hai con số chỉ so được khi cùng giao thức. Đề tài chấm theo giao thức chuẩn của lĩnh vực sinh báo cáo X-quang: tách từ bằng PTBTokenizer và tính BLEU, METEOR, ROUGE-L, CIDEr bằng thư viện pycocoevalcap [10], là bộ công cụ mà R2Gen [11] và nhiều công trình sau dùng để báo cáo trên tập kiểm tra chính thức của MIMIC-CXR. BERTScore được tính bằng thư viện bert_score với mô hình RoBERTa-large. Bộ chấm nội bộ của mã nguồn dùng METEOR của nltk và BERTScore với DistilBERT, cho giá trị khác hẳn giao thức chuẩn, nên chỉ được dùng cho so sánh nội bộ. Bài báo gốc không nêu bộ công cụ chấm điểm.

2.2. BLEU

BLEU-n đo độ chính xác của các n-gram trong báo cáo sinh ra so với báo cáo tham chiếu, kèm hệ số phạt khi báo cáo ngắn hơn tham chiếu [12]. BLEU-1 phản ánh việc

dùng đúng từ vựng, BLEU-4 phản ánh việc tái tạo đúng cụm từ dài. Đề tài báo cáo BLEU-1 đến BLEU-4 vì đây là độ đo mà mọi công trình sinh báo cáo trên MIMIC-CXR đều báo cáo, kể cả bài báo gốc, nên là cơ sở chung tối thiểu để đặt kết quả cạnh nhau. Hạn chế của BLEU là không phân biệt được một câu phủ định với câu khẳng định có cùng từ vựng, nên không phản ánh độ đúng lâm sàng.

2.3. METEOR

METEOR tính trung bình điều hòa có trọng số của độ chính xác và độ nhạy ở mức từ đơn, có khớp theo gốc từ và từ đồng nghĩa, cộng hình phạt khi thứ tự từ bị phân mảnh [13]. Đề tài dùng METEOR 1.5, phiên bản trong pycocoevalcap. METEOR bổ sung cho BLEU ở hai điểm: nó thưởng độ nhạy, tức việc nhắc lại được nội dung của tham chiếu, và chấp nhận cách diễn đạt khác từ. Vì thưởng độ nhạy, METEOR giảm mạnh khi báo cáo sinh ra quá ngắn, nên luôn được đọc cùng độ dài báo cáo.

2.4. ROUGE-L

ROUGE-L dựa trên dãy con chung dài nhất giữa báo cáo sinh ra và tham chiếu, tính dưới dạng F-measure [14]. Khác BLEU, ROUGE-L không yêu cầu các từ khớp phải liền nhau, nên phản ánh việc giữ đúng trình tự nội dung ở mức câu, một đặc điểm quan trọng của báo cáo X-quang vốn thường mô tả theo trình tự giải phẫu.

2.5. CIDEr

CIDEr biểu diễn mỗi báo cáo bằng vector n-gram có trọng số TF-IDF trên toàn tập tham chiếu và đo độ tương đồng cosin với tham chiếu [15]. Trọng số IDF làm giảm đóng góp của các cụm từ lặp lại ở hầu hết báo cáo, như các câu mô tả phổi bình thường, và tăng đóng góp của các cụm từ đặc trưng cho từng ca. Đề tài dùng CIDEr như độ đo ít bị chi phối bởi văn mẫu nhất trong nhóm độ đo từ vựng. Tuy vậy CIDEr cũng có thể tăng khi mô hình sinh các câu ngắn khớp đúng cụm từ đặc trưng, nên không được dùng riêng lẻ để kết luận.

2.6. BERTScore

BERTScore so khớp từng token của báo cáo sinh ra với token gần nhất của tham chiếu trong không gian biểu diễn ngữ cảnh của một mô hình ngôn ngữ, rồi tính F1 trên các độ tương đồng đó [16]. Độ đo này ghi nhận các cách diễn đạt khác từ nhưng cùng

nghĩa mà các độ đo n-gram bỏ sót. Đề tài báo cáo cả giá trị thô và giá trị đã co giãn theo đường cơ sở. Giá trị thô với RoBERTa-large tập trung quanh 0,85 cho mọi văn bản tiếng Anh trôi chảy, còn giá trị co giãn đưa mức của hai văn bản không liên quan về gần 0 để chênh lệch dễ đọc hơn. Bài báo gốc báo cáo BERTScore 0,426 mà không nêu mô hình nền hay việc co giãn; giá trị này nằm xa mức 0,85 của giá trị thô, nên không đặt được cạnh con số của đề tài khi chưa biết giao thức.

2.7. Độ dài và tỉ lệ lặp của báo cáo sinh ra

Đề tài báo cáo thêm hai đại lượng chẩn đoán không phải độ đo chất lượng. Trung vị số từ của báo cáo sinh ra được đặt cạnh trung vị của báo cáo tham chiếu, vì BLEU và METEOR đều phụ thuộc mạnh vào độ dài. Tỉ lệ báo cáo chứa một 5-gram lặp lại từ 3 lần trở lên đo hiện tượng suy biến khi giải mã tham lam, một lỗi đã được ghi nhận rộng rãi ở các mô hình ngôn ngữ [17]. Chính đại lượng này giúp phát hiện lỗi điều kiện dừng sinh của đề tài: trên 25 nghiên cứu kiểm định, tỉ lệ lặp giảm từ 64% xuống 0% sau khi sửa lỗi. Độ dài 5-gram được chọn vì báo cáo của bác sĩ hiếm khi lặp một cụm năm từ, trong khi các cụm ba từ lặp lại là bình thường trong văn phong X-quang.

2.8. Độ đo lâm sàng chưa được triển khai

Các độ đo từ vựng không đo độ đúng lâm sàng: một báo cáo nói "không có tràn dịch màng phổi" và một báo cáo nói "có tràn dịch màng phổi" có BLEU gần như nhau. Các công trình gần đây vì vậy báo cáo thêm độ đo hiệu quả lâm sàng, tính F1 giữa nhãn do CheXpert hoặc CheXbert trích từ báo cáo sinh ra và từ báo cáo tham chiếu [11], [18]; RadGraph F1, đo mức trùng khớp thực thể và quan hệ lâm sàng [19]; và RadCliQ, độ đo tổng hợp được hiệu chỉnh theo đánh giá của bác sĩ [20]. Bài báo gốc báo cáo cả ba nhóm: RadGraph F1 0,224, RadCliQ 1,211 và F1 hiệu quả lâm sàng 0,428. Đề tài chưa triển khai các độ đo này vì chúng là mã nghiên cứu với giấy phép và phiên bản riêng, chưa được đối chiếu với điểm tham chiếu đã công bố. Theo nguyên tắc của đề tài, một độ đo chưa có được ghi là không có, không bao giờ ghi là 0, và các độ đo từ vựng không được trình bày như độ đúng lâm sàng.

2.9. Kiểm tra độ tin cậy của lời giải thích

Với bản đồ giải thích của Giai đoạn 2, đề tài không dùng độ đo chất lượng hình ảnh mà dùng hai phép kiểm tra hợp lệ của Adebayo và cộng sự [21]. Phép thay ảnh đo mức

tăng log-likelihood âm của báo cáo đích khi thay ảnh của nghiên cứu bằng ảnh của một nghiên cứu khác; khoảng tin cậy bootstrap phải loại trừ 0 thì mới kết luận mô hình dùng thông tin ảnh. Phép ngẫu nhiên hóa trọng số khởi tạo lại dần các lớp của mô hình ngôn ngữ từ trên xuống và đo tương quan hạng Spearman giữa bản đồ mới và bản đồ gốc; tương quan phải giảm dần về gần 0, nếu không bản đồ chỉ phản ánh đầu vào chứ không phản ánh mô hình. Bài báo gốc trình bày bản đồ chú ý của token chuyên gia và đánh giá của chuyên gia trên 8 ảnh, nhưng không có phép kiểm tra hợp lệ nào.

2.10. Tóm tắt độ đo Giai đoạn 2

Bảng 2.1. *Các độ đo sinh báo cáo và đối chiếu với bài báo gốc*

Độ đo	Phản ánh	Trong đề tài	Bài báo gốc
BLEU-1 đến BLEU-4	Độ chính xác n-gram	pycocoevalcap	Có
METEOR	Độ nhạy từ, có đồng nghĩa	METEOR 1.5	Có
ROUGE-L	Trình tự nội dung	pycocoevalcap	Có
CIDEr	Cụm từ đặc trưng từng ca	pycocoevalcap	Có
BERTScore	Tương đồng ngữ nghĩa	RoBERTa-large, thô và co giãn	Có, không nêu cài đặt
Độ dài, tỉ lệ lặp	Chẩn đoán lỗi sinh	Trung vị từ, 5-gram lặp 3 lần	Không
F1 hiệu quả lâm sàng	Độ đúng nhãn bệnh	Chưa có	Có
RadGraph F1, RadCliQ	Độ đúng thực thể lâm sàng	Chưa có	Có
Phép thay ảnh, ngẫu nhiên hóa	Độ tin cậy lời giải thích	Có, kèm khoảng tin cậy	Không

TÀI LIỆU THAM KHẢO

[1] D. Edirisinghe, W. Nimalsiri, M. Hennayake, D. Meedeniya, and G. Lim, "Chest X-ray report generation using abnormality guided vision language model," IEEE Access, vol. 13, pp. 157651-157673, 2025, doi: 10.1109/ACCESS.2025.3606961.

[2] J. Irvin et al., "CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison," in Proc. AAAI Conf. Artif. Intell., vol. 33, 2019, pp. 590-597.

[3] L. Seyyed-Kalantari, G. Liu, M. McDermott, I. Y. Chen, and M. Ghassemi, "CheXclusion: Fairness gaps in deep chest X-ray classifiers," in Proc. Pacific Symp. Biocomputing, 2021, pp. 232-243.

[4] J. A. Hanley and B. J. McNeil, "The meaning and use of the area under a receiver operating characteristic (ROC) curve," Radiology, vol. 143, no. 1, pp. 29-36, 1982.

[5] T. Fawcett, "An introduction to ROC analysis," Pattern Recognit. Lett., vol. 27, no. 8, pp. 861-874, 2006.

[6] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," PLoS ONE, vol. 10, no. 3, Art. no. e0118432, 2015.

[7] Z. C. Lipton, C. Elkan, and B. Naryanaswamy, "Optimal thresholding of classifiers to maximize F1 measure," in Proc. ECML PKDD, 2014, pp. 225-239.

[8] W. J. Youden, "Index for rating diagnostic tests," Cancer, vol. 3, no. 1, pp. 32-35, 1950.

[9] B. Efron and R. J. Tibshirani, An Introduction to the Bootstrap. New York, NY, USA: Chapman and Hall, 1993.

[10] X. Chen et al., "Microsoft COCO captions: Data collection and evaluation server," arXiv:1504.00325, 2015.

[11] Z. Chen, Y. Song, T.-H. Chang, and X. Wan, "Generating radiology reports via memory-driven transformer," in Proc. EMNLP, 2020, pp. 1439-1449.

[12] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, "BLEU: A method for automatic evaluation of machine translation," in Proc. 40th Annu. Meeting Assoc. Comput. Linguistics, 2002, pp. 311-318.

[13] M. Denkowski and A. Lavie, "Meteor Universal: Language specific translation evaluation for any target language," in Proc. 9th Workshop Statistical Machine Translation, 2014, pp. 376-380.

[14] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in Text Summarization Branches Out, 2004, pp. 74-81.

[15] R. Vedantam, C. L. Zitnick, and D. Parikh, "CIDEr: Consensus-based image description evaluation," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2015, pp. 4566-4575.

[16] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT," in Proc. Int. Conf. Learn. Represent., 2020.

[17] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi, "The curious case of neural text degeneration," in Proc. Int. Conf. Learn. Represent., 2020.

[18] A. Smit, S. Jain, P. Rajpurkar, A. Pareek, A. Y. Ng, and M. P. Lungren, "CheXbert: Combining automatic labelers and expert annotations for accurate radiology report labeling using BERT," in Proc. EMNLP, 2020, pp. 1500-1519.

[19] S. Jain et al., "RadGraph: Extracting clinical entities and relations from radiology reports," in Proc. NeurIPS Datasets and Benchmarks Track, 2021.

[20] F. Yu et al., "Evaluating progress in automatic chest X-ray radiology report generation," Patterns, vol. 4, no. 9, Art. no. 100802, 2023.

[21] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, and B. Kim, "Sanity checks for saliency maps," in Proc. Adv. Neural Inf. Process. Syst., 2018, pp. 9505-9515.