NHỮNG ĐIỂM MỚI CỦA ĐỀ TÀI SO VỚI BÀI BÁO META-CXR GỐC

Đối chiếu từng thành phần, lý do thay đổi và bằng chứng thực nghiệm

PHẠM VI VÀ NGUỒN ĐỐI CHIẾU

Tài liệu này so sánh pipeline của đề tài với bài báo META-CXR gốc của Edirisinghe và cộng sự, công bố trên IEEE Access năm 2025 [1]. Nội dung bài báo được đọc từ bản toàn văn, gồm phần phương pháp, các bảng kết quả và các nghiên cứu cắt bỏ. Ở những điểm bài báo mô tả khác với mã nguồn công khai của chính nhóm tác giả [2], tài liệu nêu cả hai. Cả hai công trình huấn luyện và đánh giá trên MIMIC-CXR-JPG theo phân chia chính thức [3]. Với mỗi thay đổi, tài liệu trình bày bài báo gốc làm gì, đề tài làm gì, vì sao thay đổi, và bằng chứng đo được. Các số liệu so sánh ghép cặp được tính trên cùng tập nghiên cứu với bootstrap 2.000 lần theo nghiên cứu; số liệu đánh dấu là ghi nhận được lấy từ nhật ký thực nghiệm của đề tài.

CHƯƠNG 1. TỔNG QUAN CÁC KHÁC BIỆT

Bảng 1.1. *Đối chiếu các thành phần chính giữa bài báo gốc và đề tài*

Thành phần	Bài báo gốc [1]	Đề tài	Lý do chính
Ô nhãn để trống	Coi là âm tính	Bị che, không tính mất mát	Không nhắc tới khác với loại trừ
Đơn vị lấy mẫu	Ảnh thẳng	Nghiên cứu, ảnh chính và ảnh phụ	Một báo cáo cho mỗi nghiên cứu
Bộ mã hóa ảnh	ResNet50 BioViL-T, ViT PubMedCLIP, Swin MedCLIP, đóng băng	BioViL-T và PubMedCLIP, mở đông lớp trên	Đo được lợi ích khi mở đông
Nhánh văn bản MHCAC	Dropout văn bản ở các lớp đầu	Giáo viên có văn bản, học sinh chỉ có ảnh	Khớp huấn luyện với suy luận
Cổng nhắc tới	Không có	Có, điểm hiện diện bằng m nhân q	Học từ ô để trống
ITC, ITM, sinh văn bản	Có trong phương pháp, tắt trong mã nguồn	Tắt	Truy hồi đo được ở mức ngẫu nhiên
Chọn ngưỡng	Điểm ROC gần góc trên trái	Vùng ổn định F1 trên tập kiểm định	Ngưỡng chuyển được sang tập kiểm tra
Mô hình ngôn ngữ	Vicuna-7B, LoRA hạng 8, INT8	MedGemma 1.5 4B, QLoRA NF4 hạng 16	Tiền huấn luyện y khoa, có bộ mã hóa ảnh riêng
Đường thị giác Giai đoạn 2	Token mềm từ META-Former	Bộ mã hóa ảnh của MedGemma, thêm token mềm	Token mềm chưa được căn chỉnh
Đánh giá	Giá trị điểm	Giao thức chuẩn, khoảng tin cậy ghép cặp	So sánh được và kiểm định được

CHƯƠNG 2. THAY ĐỔI Ở DỮ LIỆU VÀ NHÃN

2.1. Ô nhãn để trống được che thay vì coi là âm tính

Bài báo gốc dùng nhãn CheXpert và coi các ô để trống là lớp âm tính để nhất quán (mục III-A của [1]). Ô để trống nghĩa là bộ gán nhãn không tìm thấy bất thường được nhắc tới trong báo cáo [4], không có nghĩa bác sĩ đã loại trừ bất thường đó. Trên MIMIC-CXR-JPG, 79,4% số ô để trống, nên gán chúng thành âm tính biến phần lớn các nhãn âm tính trong dữ liệu huấn luyện thành sự vắng mặt của thông tin. Đề tài gán ô để trống giá trị bỏ qua và loại chúng khỏi hàm mất mát phân loại theo từng ô. Thông tin mà các ô này mang, tức bất thường có được nhắc tới hay không, được khai thác bằng một đầu dự đoán riêng mô tả ở mục 3.3.

Hệ quả là nhãn huấn luyện của đề tài không còn chứa các nhãn âm tính được tạo ra từ ô để trống. Đổi lại, bài toán ba lớp khi chỉ xét ô được nhắc tới lại có dương tính chiếm đa số, nên đề tài báo cáo F1 theo cách diễn giải hiện diện trong nghiên cứu, trùng với chính sách U-Zeros của CheXpert và cách đánh giá của CheXclusion [4], [5].

2.2. Lấy mẫu theo nghiên cứu và dùng mọi tư thế chụp

Bài báo gốc chỉ dùng ảnh chụp thẳng và mô tả số lượng theo ảnh (Bảng 1 của [1]). Một nghiên cứu trong MIMIC-CXR có thể gồm nhiều ảnh nhưng chỉ có một báo cáo, nên lấy mẫu theo ảnh làm các nghiên cứu nhiều ảnh bị lặp báo cáo và có trọng số lớn hơn. Đề tài lấy mẫu theo nghiên cứu: mỗi nghiên cứu chọn một ảnh chính theo thứ tự PA, AP, nghiêng và tối đa một ảnh phụ có tư thế khác. Trên tập huấn luyện, 105.462 trong 222.758 nghiên cứu có ảnh phụ như vậy. Ảnh phụ được đưa vào mô-đun hợp nhất góc nhìn, trong đó token của ảnh chính làm truy vấn và token của ảnh phụ làm khóa và giá trị. Lớp chiếu đầu ra của mô-đun được khởi tạo bằng 0 để mô-đun là phép đồng nhất ở bước đầu, nên nghiên cứu một ảnh không bị ảnh hưởng. Lý do là ảnh nghiêng cho thấy những vùng mà ảnh thẳng che khuất, như góc sườn hoành phía sau. Đề tài chưa có nghiên cứu cắt bỏ riêng cho mô-đun này, nên đây là thay đổi có cơ sở thiết kế nhưng chưa có bằng chứng định lượng tách riêng.

2.3. Trích xuất phần FINDINGS có kiểm soát

Bài báo gốc không mô tả cách lấy văn bản đích từ báo cáo. Đề tài dùng bộ phân tích riêng để tách FINDINGS và IMPRESSION, khôi phục phần tường thuật khi báo cáo không có tiêu đề FINDINGS thay vì lấy toàn bộ báo cáo, không bao giờ dùng

IMPRESSION thay cho FINDINGS, và loại các đích quá ngắn hoặc dài hơn phân vị 99% tính trên tập huấn luyện. Nghiên cứu không có đích hợp lệ vẫn được dùng cho phân loại nhưng bị che khỏi hàm mất mát sinh báo cáo.

CHƯƠNG 3. THAY ĐỔI Ở GIAI ĐOẠN 1

3.1. Bộ mã hóa ảnh và cách giữ nguyên cấu trúc token

Bài báo gốc mô tả ba bộ mã hóa đóng băng: BioViL-T với lõi ResNet50, PubMedCLIP với lõi ViT và MedCLIP với lõi Swin, chiếu về 1.408 chiều rồi nối lại (mục III-B và III-E của [1]). Mã nguồn công khai của nhóm tác giả chỉ đưa đặc trưng của BioViL-T và PubMedCLIP vào MHCAC [2]. Đề tài dùng hai bộ mã hóa này [6], [7] và tắt Swin, vì với bộ nhớ 16 GB việc giữ Swin buộc phải giảm kích thước lô, và cấu hình hai bộ mã hóa cho phép giữ nguyên cấu trúc token gốc của từng bộ.

Đề tài sửa ba điểm trong cách đưa token vào MHCAC. Thứ nhất, mỗi bộ mã hóa giữ nguyên độ phân giải gốc: BioViL-T cho lưới 14 nhân 14, PubMedCLIP cho token CLS toàn cục và lưới 7 nhân 7, thay vì thu nhỏ về cùng kích thước và bỏ token CLS. Token CLS của PubMedCLIP không khôi phục được từ các token vùng, còn đầu ra toàn cục của BioViL-T chính là trung bình các token vùng, nên việc bỏ CLS đã bỏ đi phần thông tin không thể thay thế. Thứ hai, token vùng của PubMedCLIP được đưa qua lớp chuẩn hóa cuối và trừ trung bình theo ảnh. Theo số liệu ghi nhận, độ tương đồng cosin trung bình giữa các token vùng của PubMedCLIP khi chưa xử lý là 0,674, so với 0,0017 của BioViL-T, tức các token gần như trùng nhau và chú ý trên chúng gần như phẳng; sau xử lý con số này là -0,014. Thứ ba, mỗi bộ mã hóa có mã hóa vị trí riêng, khởi tạo với độ lệch chuẩn 0,02, để token thứ k của hai bộ mã hóa không nhận cùng một vector vị trí.

3.2. Mở đông một phần bộ mã hóa ảnh

Bài báo gốc giữ đóng băng các bộ mã hóa ảnh; ở pha cuối chỉ các lớp chiếu phía sau bộ mã hóa được tinh chỉnh cùng META-Former (mục III-E của [1]). Với bộ mã hóa đóng băng, hàm mất mát phân loại chỉ có thể điều chỉnh các lớp chiếu và MHCAC đọc trên một bản đồ đặc trưng cố định. Đề tài mở đông khối layer4 và lớp chiếu của BioViL-T cùng hai khối Transformer cuối và lớp chuẩn hóa cuối của PubMedCLIP, tổng cộng 31,85 triệu tham số, với tốc độ học 1e-5, thấp hơn mười lần so với phần còn lại. So với cấu hình đóng băng trên 3.269 nghiên cứu kiểm tra, AUROC macro thay đổi +0,0201,

khoảng tin cậy [+0,0139; +0,0266], và F1 dương tính macro thay đổi +0,0144, khoảng tin cậy [+0,0053; +0,0231]. Trong các thay đổi huấn luyện đã được đo có đối chứng, đây là thay đổi duy nhất làm AUROC macro tăng có ý nghĩa thống kê. Cần lưu ý trọng số lớp được đổi cùng lần chạy này, nên đóng góp của hai thay đổi chưa được tách riêng hoàn toàn; lập luận quy tăng AUROC cho việc mở đông dựa trên việc trọng số lớp chỉ dời điểm hoạt động chứ không đổi được AUROC. Mở đông sâu hơn không cho thêm lợi ích có ý nghĩa: AUROC macro thay đổi +0,0049, khoảng tin cậy [-0,0002; +0,0098].

3.3. Đầu cổng nhắc tới

Đây là thành phần mới không có trong bài báo gốc. Bên cạnh đầu phân loại ba lớp, MHCAC có thêm một đầu nhị phân cho mỗi bất thường, dự đoán bất thường đó có được nhắc tới trong báo cáo hay không. Đầu này là thành phần duy nhất học từ các ô để trống, và được huấn luyện bằng entropy chéo nhị phân có trọng số theo tỉ lệ ô không nhắc tới trên ô được nhắc tới nhân hệ số 2, giới hạn trên bằng 10 để tránh thiên lệch về lớp đa số. Khi đánh giá, xác suất hiện diện được tính bằng xác suất được nhắc tới nhân với xác suất dương tính khi được nhắc tới, đúng với câu hỏi nghiên cứu có bất thường hay không. Lý do cần đầu này là trước khi có nó, mô hình buộc phải chọn một trong ba lớp cho cả 14 bất thường trên mọi ảnh và theo số liệu ghi nhận đã gọi dương tính trung bình 10,8 trên 14 bất thường mỗi nghiên cứu. Trên cùng mô hình và cùng 3.269 nghiên cứu kiểm tra, dùng điểm hiện diện thay cho xác suất dương tính có điều kiện làm AUROC macro thay đổi +0,0616, khoảng tin cậy [+0,0527; +0,0706].

3.4. Tách giáo viên và học sinh cho nhánh văn bản

Trong bài báo gốc, các token chuyên gia chung của MHCAC chú ý chéo với văn bản báo cáo trong các lớp đầu, có áp dụng dropout lên đặc trưng văn bản, trong khi lúc suy luận không có văn bản (mục III-D của [1]). Thiết kế này để một mạng duy nhất gặp hai phân phối đầu vào khác nhau giữa huấn luyện và suy luận. Đề tài tách thành hai nhánh: nhánh giáo viên đọc cả ảnh và văn bản, chỉ tồn tại khi huấn luyện; nhánh học sinh chỉ đọc ảnh và là nhánh dùng khi suy luận. Nhánh học sinh học từ nhãn và từ phân phối dự đoán của giáo viên qua chưng cất tri thức với nhiệt độ 2 [8], theo tinh thần học với thông tin đặc quyền, trong đó thông tin chỉ có lúc huấn luyện được dùng để hướng dẫn một mô hình không có thông tin đó [9]. Nhờ vậy đường suy luận không bao giờ nhìn thấy

văn bản và không có sai lệch phân phối giữa hai giai đoạn. Đề tài chưa có nghiên cứu cắt bỏ riêng cho việc tách này.

3.5. Tắt khối căn chỉnh ảnh và văn bản của Q-Former

Bài báo gốc mô tả META-Former được huấn luyện với ba mục tiêu của BLIP-2 là đối sánh tương phản ảnh và văn bản, khớp ảnh và văn bản, và sinh văn bản dựa trên ảnh [1], [10]. Tuy vậy, trong mã nguồn công khai của nhóm tác giả toàn bộ khối tính các mất mát này bị chú thích bỏ, và hàm mất mát trả về chỉ gồm mất mát phân loại cộng 0,3 lần mất mát tương phản, 0,7 lần mất mát trực giao và 0,3 lần mất mát thưa của MHCAC [2]. Đề tài giữ đúng ba trọng số này.

Đề tài đã bật lại khối căn chỉnh và đo trực tiếp bằng phép kiểm tra truy hồi trên 256 cặp ảnh và báo cáo kiểm định. Theo số liệu ghi nhận, ba lần đo sau khoảng 500 bước cập nhật, với nhiệt độ học được và với nhiệt độ cố định, đều cho thứ hạng truy hồi trung bình từ 127,4 đến 128,4, trong khi mức ngẫu nhiên là 127,5. Nguyên nhân phù hợp nhất là kích thước lô: BLIP-2 huấn luyện đối sánh tương phản với lô 1.680 đến 2.320 cặp [10], trong khi với GPU 16 GB lô của đề tài chỉ là 8, nên các mẫu âm trong lô quá dễ để tạo tín hiệu học. Đề tài vì vậy tắt khối này. Hệ quả cần nêu rõ là 32 token mềm của Q-Former không được căn chỉnh với ảnh y khoa, và điều này định hướng lại thiết kế Giai đoạn 2 ở mục 4.2. Một phép thăm dò tuyến tính trên các token này vẫn đạt AUROC macro 0,6847 trên 10 bất thường so với 0,4838 khi xáo trộn nhãn, nên chúng mang tín hiệu nhưng chỉ là một phép đọc cố định.

3.6. Các mất mát bổ sung

Ngoài bốn mất mát của MHCAC, đề tài thêm ba mất mát. Mất mát cổng nhắc tới và mất mát chưng cất đã mô tả ở trên. Mất mát tương phản đa dương tính giữa hai góc nhìn của cùng nghiên cứu, theo dạng của SimCLR [11], với trọng số 0,02 và một bộ điều hợp dư sau mỗi bộ mã hóa. Bộ điều hợp là cần thiết vì mất mát này ban đầu được tính trên đặc trưng của bộ mã hóa đóng băng nên không có tham số nào phía trước nhận gradient; theo số liệu ghi nhận, giá trị mất mát đứng yên ở khoảng 3,99 qua bốn epoch. Cuối cùng là mất mát nhất quán góc nhìn dạng mềm, chỉ phạt khi phân kỳ vượt một ngưỡng và bỏ qua các ô mà việc hợp nhất làm dự đoán tự tin hơn, vì ảnh phụ tồn tại chính để thay đổi

dự đoán ở những vùng ảnh chính không thấy. Các mất mát bổ sung này chưa có nghiên cứu cắt bỏ riêng.

3.7. Hiệu chuẩn ngưỡng và cách chấm phân loại

Bài báo gốc chọn ngưỡng cho từng lớp tại điểm trên đường cong ROC gần góc trên bên trái nhất và báo cáo độ chính xác, độ nhạy, F1 trung bình cho bài toán ba lớp (mục IV-B và V-C của [1]), không nêu tập dùng để chọn ngưỡng. Đề tài chỉ chọn ngưỡng trên tập kiểm định, tối đa hóa F1 dưới cách diễn giải hiện diện trong nghiên cứu, đặt ngưỡng ở trung vị vùng đạt ít nhất 95% F1 cực đại và yêu cầu ít nhất 5 mẫu dương tính. Lý do thứ nhất là F1 chỉ có ý nghĩa khi các bộ phân loại hằng số không đạt được nó. Khi ô trống bị che và chỉ xét các ô được nhắc tới, một bộ phân loại luôn dự đoán dương tính đã đạt F1 0,8397 trên tập kiểm tra, so với 0,2280 dưới cách diễn giải hiện diện trong nghiên cứu. Với cách làm của bài báo gốc, ô trống được tính là âm tính nên lớp âm tính chiếm phần lớn số ô; nếu độ chính xác, độ nhạy và F1 được lấy trung bình có trọng số theo số mẫu như nghiên cứu cắt bỏ của bài báo ghi, con số trung bình sẽ bị chi phối bởi lớp âm tính, vốn là lớp dễ nhất. Lý do thứ hai là ngưỡng tối thiểu 5 mẫu giúp hiệu chuẩn được hai nhãn hiếm Pleural Other và Fracture, làm F1 macro thay đổi +0,0181, khoảng tin cậy [+0,0140; +0,0227]; riêng việc chọn vùng ổn định thay cho đỉnh chỉ thay đổi +0,0027 và chưa có ý nghĩa thống kê.

CHƯƠNG 4. THAY ĐỔI Ở GIAI ĐOẠN 2

4.1. Mô hình ngôn ngữ

Bài báo gốc dùng Vicuna-7B lượng tử hóa INT8 với LoRA hạng 8, alpha 16, chỉ cập nhật lớp chiếu đầu ra của META-Former và LoRA (mục III-E và V-B của [1]). Đề tài dùng MedGemma 1.5 4B-it [12] lượng tử hóa NF4 theo QLoRA [13], với LoRA [14] hạng 16, alpha 32 chỉ trên tháp ngôn ngữ, tổng cộng 31,77 triệu tham số huấn luyện, bằng 1,26% mô hình. Có ba lý do. MedGemma được tiền huấn luyện trên dữ liệu y khoa gồm cả ảnh X-quang ngực, nên xuất phát điểm gần miền bài toán hơn một mô hình trò chuyện tổng quát. MedGemma có bộ mã hóa ảnh riêng, cho phép thiết kế đường thị giác không phụ thuộc token mềm chưa được căn chỉnh. Cuối cùng, mô hình 4 tỉ tham số lượng tử hóa 4 bit vừa với GPU 16 GB khi huấn luyện toàn bộ một epoch trên tập huấn luyện.

4.2. Đường thị giác của Giai đoạn 2

Trong bài báo gốc, mô hình ngôn ngữ chỉ nhìn ảnh qua các token truy vấn của META-Former, kèm danh sách bất thường dương tính, âm tính và không chắc chắn vượt ngưỡng trong lời nhắc (mục III-E.3 của [1]). Vì khối căn chỉnh của Q-Former không học được như trình bày ở mục 3.5, đề tài xây dựng hai hệ thống. Hệ thống A dùng trực tiếp bộ mã hóa ảnh của MedGemma trên ảnh chính, không dùng thông tin Giai đoạn 1. Hệ thống C giữ bộ mã hóa ảnh của MedGemma và bổ sung 32 token mềm cùng gợi ý từ MHCAC, tức trả lời câu hỏi token mềm và gợi ý đóng góp thêm được gì, thay vì câu hỏi token mềm có thay thế được ảnh hay không. Việc thay token mềm vào đúng vị trí của từng mẫu được kiểm tra theo từng hàng và dừng hẳn khi sai số lượng, vì lỗi chỉ số ở đây không làm mất mát bất thường nhưng khiến mỗi báo cáo mô tả ảnh của một nghiên cứu khác.

Kết quả trên 2.772 nghiên cứu kiểm tra cho thấy tinh chỉnh hệ thống A so với MedGemma không tinh chỉnh làm CIDEr thay đổi +0,0647, khoảng tin cậy [+0,0376; +0,0957], nhưng METEOR thay đổi -0,0274, khoảng tin cậy [-0,0313; -0,0233], chủ yếu vì báo cáo sinh ra ngắn hơn: trung vị 31 từ so với 56 từ của tham chiếu. Hệ thống A chỉ hoàn thành 0,86 epoch và không có bước chọn checkpoint, còn hệ thống C hoàn thành trọn một epoch.

4.3. Quy tắc tạo gợi ý và trạng thái gợi ý

Bài báo gốc đưa vào lời nhắc mọi bất thường có độ tin cậy vượt ngưỡng của từng lớp [1]. Đề tài tách ba trạng thái mà cách làm cũ gộp chung: không cung cấp gợi ý, mô hình từ chối kết luận vì không bất thường nào vượt ngưỡng, và có dự đoán. Hai trạng thái đầu không sinh khối gợi ý nào, còn tóm tắt dạng bình thường chỉ được phép khi cả 13 bất thường đều được dự đoán âm tính. Lý do là trong cách làm cũ, danh sách rỗng bị diễn đạt thành một câu khẳng định bình thường, tức đưa vào lời nhắc một kết luận mà mô hình phân loại chưa đưa ra. Quy tắc mặc định dùng xác suất hiện diện thay cho xác suất dương tính có điều kiện.

Bằng chứng thực nghiệm về gợi ý là âm tính và cần được nêu rõ. Trên 100 nghiên cứu kiểm định với cùng một checkpoint, không quy tắc nào trong năm quy tắc tạo gợi ý, kể cả các quy tắc có độ chính xác cao gấp đôi quy tắc cũ, cải thiện có ý nghĩa so với không dùng gợi ý trên METEOR, ROUGE-L, CIDEr hay BERTScore. Thử nghiệm đưa

thông tin Giai đoạn 1 qua 13 token học được thay cho câu chữ, trên 300 nghiên cứu, còn làm BERTScore thô thay đổi -0,0041, khoảng tin cậy [-0,0066; -0,0017], so với không dùng gợi ý. Điểm mới của đề tài ở đây vì vậy là đã kiểm định có đối chứng và bác bỏ, trong chế độ huấn luyện đã thử, giả định rằng đưa kết quả phân loại vào lời nhắc giúp sinh báo cáo tốt hơn, một giả định mà bài báo gốc chỉ minh họa định tính.

4.4. Sửa điều kiện dừng sinh

Đây là sửa lỗi kỹ thuật chứ không phải cải tiến phương pháp, nhưng ảnh hưởng tới mọi số liệu Giai đoạn 2. Báo cáo đích khi huấn luyện kết thúc bằng mã end_of_turn của MedGemma, trong khi mã nguồn ban đầu ghi đè danh sách mã dừng bằng mã kết thúc của bộ tách từ. Theo số liệu ghi nhận trên 25 nghiên cứu kiểm định, 3.112 trong 4.000 token sinh ra nằm sau mã end_of_turn. Sau khi sửa, trên cùng 25 nghiên cứu, CIDEr thay đổi +0,2525, khoảng tin cậy [+0,1124; +0,4163], và tỉ lệ báo cáo có 5-gram lặp giảm từ 64% xuống 0%.

4.5. Giao thức đánh giá

Bài báo gốc báo cáo giá trị điểm của các độ đo, không kèm khoảng tin cậy, không nêu bộ công cụ chấm điểm và không nêu cài đặt BERTScore [1]. Đề tài chấm bằng giao thức chuẩn pycocoevalcap [15] và BERTScore RoBERTa-large ở cả dạng thô và co giãn, so sánh mọi cặp hệ thống trên đúng một tập nghiên cứu được kiểm tra trùng khớp định danh băm, và báo cáo khoảng tin cậy bootstrap ghép cặp [16]. Đề tài cũng theo dõi tỉ lệ lặp n-gram [17], là đại lượng đã phát hiện lỗi điều kiện dừng. Với lời giải thích, bài báo gốc trình bày bản đồ chú ý của token chuyên gia; đề tài chỉ xuất bản đồ khi hai phép kiểm tra hợp lệ đạt [18], với bản đồ tính bằng lan truyền chú ý có trọng số gradient [19] trên MedGemma: thay ảnh bằng ảnh nghiên cứu khác phải làm log-likelihood âm tăng có ý nghĩa, và ngẫu nhiên hóa dần trọng số phải làm bản đồ suy biến.

CHƯƠNG 5. ĐẶT KẾT QUẢ CẠNH BÀI BÁO GỐC

Bảng 5.1. *Độ đo sinh báo cáo trên tập kiểm tra MIMIC-CXR của bài báo gốc và của đề tài*

Hệ thống	BLEU-1	BLEU-4	METEOR	ROUGE-L	CIDEr
META-CXR, bài báo gốc [1]	0,390	0,102	0,173	0,280	0,291
Đề tài, hệ thống A	0,164	0,045	0,096	0,191	0,144
Đề tài, hệ thống C	0,092	0,028	0,080	0,173	0,195

Bài báo gốc: 3.269 nghiên cứu kiểm tra, không nêu bộ công cụ và phần báo cáo được chấm. Đề tài: 2.772 nghiên cứu kiểm tra có FINDINGS hợp lệ, chấm phần FINDINGS bằng pycocoevalcap.

Trên các độ đo từ vựng, cả hai hệ thống của đề tài đều thấp hơn con số bài báo gốc công bố. Hai bên dùng cùng phân chia chính thức của MIMIC-CXR-JPG [3], nhưng không cùng tập con nghiên cứu, không chắc cùng phần báo cáo đích và không chắc cùng bộ công cụ, nên bảng trên cho thấy vị trí tương đối chứ không phải một phép so sánh có kiểm soát. Một phần khoảng cách đến từ việc báo cáo sinh ra của đề tài ngắn hơn tham chiếu, làm giảm BLEU qua hệ số phạt độ ngắn và giảm METEOR vốn thưởng độ nhạy. Ở Giai đoạn 1, bài báo gốc báo cáo F1 0,73 cho bài toán ba lớp với ô trống là âm tính, còn đề tài báo cáo AUROC macro 0,7643 và F1 dương tính macro 0,3542 dưới cách diễn giải hiện diện trong nghiên cứu; hai con số F1 trả lời hai câu hỏi khác nhau và không đặt cạnh nhau được.

CHƯƠNG 6. CÁC HƯỚNG ĐÃ THỬ NHƯNG KHÔNG GIỮ LẠI

Bảng 6.1. *Các thay đổi đã thử có đối chứng nhưng không đưa vào mô hình chính*

Thay đổi	Kết quả	Kết luận
Mở đông sâu hơn	AUROC macro +0,0049, chưa có ý nghĩa	Không giữ
Hàm mất mát phân cấp	AUROC micro +0,0273 có ý nghĩa, AUROC macro +0,0047 chưa có ý nghĩa	Chỉ cải thiện hiệu chuẩn giữa nhãn
Mất mát giải thích Grad-CAM	Không tăng phân loại, bản đồ ở mức ngẫu nhiên, ghi nhận	Tắt
Huấn luyện thêm 5 epoch	AUROC macro trên tập kiểm tra -0,0005, ghi nhận	Không giữ
Bật lại ITC và ITM	Truy hồi ở mức ngẫu nhiên qua các lần đo, ghi nhận	Tắt
Năm quy tắc tạo gợi ý	Không quy tắc nào cải thiện có ý nghĩa	Không chứng minh được lợi ích
Token phát hiện học được	BERTScore thô -0,0041 so với không gợi ý	Không giữ

TÀI LIỆU THAM KHẢO

[1] D. Edirisinghe, W. Nimalsiri, M. Hennayake, D. Meedeniya, and G. Lim, "Chest X-ray report generation using abnormality guided vision language model," IEEE Access, vol. 13, pp. 157651-157673, 2025, doi: 10.1109/ACCESS.2025.3606961.

[2] D. Edirisinghe, "META-CXR: Multimodal expert tokens-based vision-language model for abnormality-guided chest X-ray reporting," GitHub repository, 2025. [Online]. Available: https://github.com/DasithEdirisinghe/META-CXR

[3] A. E. W. Johnson et al., "MIMIC-CXR-JPG, a large publicly available database of labeled chest radiographs," arXiv:1901.07042, 2019.

[4] J. Irvin et al., "CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison," in Proc. AAAI Conf. Artif. Intell., vol. 33, 2019, pp. 590-597.

[5] L. Seyyed-Kalantari, G. Liu, M. McDermott, I. Y. Chen, and M. Ghassemi, "CheXclusion: Fairness gaps in deep chest X-ray classifiers," in Proc. Pacific Symp. Biocomputing, 2021, pp. 232-243.

[6] S. Bannur et al., "Learning to exploit temporal structure for biomedical vision-language processing," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit., 2023, pp. 15016-15027.

[7] S. Eslami, C. Meinel, and G. de Melo, "PubMedCLIP: How much does CLIP benefit visual question answering in the medical domain?" in Findings Assoc. Comput. Linguistics: EACL, 2023, pp. 1181-1193.

[8] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network," arXiv:1503.02531, 2015.

[9] V. Vapnik and A. Vashist, "A new learning paradigm: Learning using privileged information," Neural Netw., vol. 22, no. 5-6, pp. 544-557, 2009.

[10] J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in Proc. Int. Conf. Mach. Learn., 2023, pp. 19730-19742.

[11] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, "A simple framework for contrastive learning of visual representations," in Proc. Int. Conf. Mach. Learn., 2020, pp. 1597-1607.

[12] A. Sellergren et al., "MedGemma technical report," arXiv:2507.05201, 2025.

[13] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in Proc. Adv. Neural Inf. Process. Syst., 2023.

[14] E. J. Hu et al., "LoRA: Low-rank adaptation of large language models," in Proc. Int. Conf. Learn. Represent., 2022.

[15] X. Chen et al., "Microsoft COCO captions: Data collection and evaluation server," arXiv:1504.00325, 2015.

[16] B. Efron and R. J. Tibshirani, An Introduction to the Bootstrap. New York, NY, USA: Chapman and Hall, 1993.

[17] A. Holtzman, J. Buys, L. Du, M. Forbes, and Y. Choi, "The curious case of neural text degeneration," in Proc. Int. Conf. Learn. Represent., 2020.

[18] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, and B. Kim, "Sanity checks for saliency maps," in Proc. Adv. Neural Inf. Process. Syst., 2018, pp. 9505-9515.

[19] H. Chefer, S. Gur, and L. Wolf, "Generic attention-model explainability for interpreting bi-modal and encoder-decoder transformers," in Proc. IEEE/CVF Int. Conf. Comput. Vis., 2021, pp. 397-406.