ĐÁNH GIÁ GIAI ĐOẠN 1 THEO GIAO THỨC CỦA BÀI BÁO META-CXR

Checkpoint run_20261005_paper (cấu hình MHCAC theo bài báo, D-026), huấn luyện xong ngày 06/10/2026

So sánh với số liệu công bố của bài báo gốc và với checkpoint trước đó run_20260930_3class

TÓM TẮT

Tài liệu này đánh giá checkpoint Giai đoạn 1 vừa huấn luyện xong lúc 02 giờ 27 ngày 06/10/2026 (run_20261005_paper, pha 1c, checkpoint_best) trên 3.269 nghiên cứu của tập test chính thức MIMIC-CXR, bằng đúng các độ đo mà bài báo META-CXR [1] sử dụng: precision, recall và F1 kiểu weighted cho từng bệnh rồi lấy trung bình 14 bệnh (Fig. 10), F1 trung bình năm bệnh (Bảng 5 và Bảng 7) và AUROC một lớp so với phần còn lại cho từng lớp (Fig. 5). Mô hình đạt precision 0,8392, recall 0,7814 và F1 0,7795, so với 0,87, 0,78 và 0,73 của bài báo; F1 trung bình năm bệnh đạt 0,6687, so với 0,701. Như vậy F1 cao hơn bài báo, recall tương đương, còn precision và F1 năm bệnh thấp hơn. So với checkpoint trước (run_20260930_3class) trên cùng các nghiên cứu, checkpoint mới tốt hơn có ý nghĩa thống kê ở bảy trên tám độ đo chính, rõ nhất là F1 năm bệnh tăng +0,0249 và AUROC lớp Không chắc chắn tăng +0,0896.

CHƯƠNG 1. THIẾT LẬP ĐÁNH GIÁ

1.1. Checkpoint được đánh giá

Checkpoint là kết quả của lịch huấn luyện ba pha của Giai đoạn 1. Pha 1a (Q-Former với ITC, ITM và LM) được dùng lại từ run_20260930_3class. Pha 1b huấn luyện MHCAC trong năm epoch và chọn epoch theo macro_recall trên tập validation; epoch được chọn là epoch 2 (đánh số từ 0). Pha 1c huấn luyện toàn bộ thêm một epoch, và checkpoint_best của pha này là checkpoint được đánh giá. So với run_20260930_3class, có ba điểm khác nhau. Thứ nhất, số expert token chung của MHCAC giảm từ 14 xuống 8 như Fig. 10 của bài báo. Thứ hai, label smoothing của hàm cross-entropy phân loại giảm từ 0,05 về 0 như phương trình (10) của bài báo. Thứ ba, tiêu chí chọn epoch ở pha 1b là

macro_recall thay cho tổng loss trên validation. Ba thay đổi này diễn ra cùng lúc nên tài liệu không tách được đóng góp riêng của từng thay đổi.

1.2. Dữ liệu

Tập test gồm 3.269 nghiên cứu, tập validation gồm 1.808 nghiên cứu, đều theo phân chia chính thức của MIMIC-CXR và lấy mẫu theo nghiên cứu. Mỗi bệnh trong 14 bệnh của CheXpert [2] có ba lớp: Âm tính, Dương tính và Không chắc chắn. Ô nhãn trống được coi là Âm tính như mục III-A của bài báo; nghiên cứu không có thông tin CheXpert nào bị loại khỏi phép tính của bệnh tương ứng.

1.3. Độ đo theo giao thức của bài báo

Với mỗi bệnh, lớp dự đoán là lớp có xác suất lớn nhất trong ba lớp (argmax). Precision, recall và F1 được tính kiểu weighted của sklearn với zero_division bằng 1 cho từng bệnh, rồi lấy trung bình cộng trên 14 bệnh; đây là ba số của Fig. 10 trong bài báo. F1 năm bệnh là trung bình F1 weighted của Atelectasis, Cardiomegaly, Consolidation, Edema và Pleural Effusion, là số 0,701 trong Bảng 5 và Bảng 7. AUROC được tính một lớp so với phần còn lại cho từng lớp của từng bệnh như Fig. 5; bài báo chỉ vẽ các đường ROC mà không công bố số trung bình nên cột bài báo ghi "không có". Khoảng tin cậy 95% được ước lượng bằng bootstrap percentile 1.000 lần lấy mẫu lại theo nghiên cứu, hạt giống 42. Lưu ý rằng recall weighted về mặt toán học bằng đúng accuracy, và với zero_division bằng 1 một lớp mà mô hình không bao giờ dự đoán vẫn có precision bằng 1, nên precision weighted có xu hướng cao khi mô hình bỏ qua lớp hiếm.

CHƯƠNG 2. KẾT QUẢ

2.1. So sánh với số liệu công bố của bài báo

Bảng 2.1. *Độ đo Giai đoạn 1 trên tập test theo giao thức của bài báo, n = 3.269 nghiên cứu*

Độ đo	Bài báo	Mô hình	KTC 95%	Chênh lệch
Precision weighted, TB 14 bệnh (Fig. 10)	0,87	0,8392	[0,8351; 0,8435]	-0,0308
Recall weighted, TB 14 bệnh (Fig. 10)	0,78	0,7814	[0,7766; 0,7857]	+0,0014
F1 weighted, TB 14 bệnh (Fig. 10)	0,73	**0,7795**	[0,7748; 0,7842]	+0,0495
F1 trung bình 5 bệnh (Bảng 5, 7)	0,701	0,6687	[0,6596; 0,6775]	-0,0323
AUROC lớp Dương, TB 14 bệnh (Fig. 5)	không có	0,7836	[0,7753; 0,7921]	không có

Độ đo	Bài báo	Mô hình	KTC 95%	Chênh lệch
AUROC lớp Âm, TB 14 bệnh (Fig. 5)	không có	0,7780	[0,7706; 0,7863]	không có
AUROC lớp Không chắc, TB 13 bệnh (Fig. 5)	không có	0,6633	[0,6308; 0,6926]	không có

Giá trị in đậm cao hơn bài báo với khoảng tin cậy không chứa số của bài báo. No Finding không có nhãn Không chắc chắn trong tập test nên AUROC lớp này lấy trung bình trên 13 bệnh.

F1 weighted của mô hình cao hơn bài báo +0,0495, và cận dưới khoảng tin cậy (0,7748) vẫn cao hơn 0,73. Recall của bài báo (0,78) nằm trong khoảng tin cậy của mô hình, nên hai giá trị là tương đương. Precision thấp hơn bài báo 0,0308 và F1 năm bệnh thấp hơn 0,0323; trong cả hai trường hợp cận trên khoảng tin cậy vẫn dưới số của bài báo. Đối chiếu này chỉ mang tính tham khảo vì bài báo không công bố danh sách nghiên cứu của tập test và code tham chiếu lấy trung bình độ đo theo từng batch rồi trung bình các batch, trong khi ở đây mỗi bệnh được tính trên toàn bộ tập test.

Độ đo weighted bị chi phối bởi lớp Âm tính vì lớp này chiếm đa số ở mọi bệnh, nên cần đặt cạnh các mô hình tham chiếu tầm thường trên cùng tập test. Bảng dưới đây cho thấy một mô hình luôn dự đoán Âm tính đã đạt F1 weighted 0,7288, gần bằng con số 0,73 của bài báo. Mô hình vượt mô hình tham chiếu này +0,0507 về F1 và +0,0504 về F1 năm bệnh, nhưng có precision và recall weighted thấp hơn nó, vì mô hình chấp nhận một số dự đoán Dương tính sai để tìm ra các ca Dương tính.

Bảng 2.2. *Mô hình so với các mô hình tham chiếu tầm thường trên cùng tập test, cùng giao thức*

Mô hình	Precision w	Recall w	F1 w	F1 5 bệnh
Mô hình đánh giá	0,8392	0,7814	**0,7795**	**0,6687**
Luôn dự đoán Âm tính	0,8616	0,8088	0,7288	0,6182
Ngẫu nhiên theo tần suất lớp	0,7118	0,7124	0,7120	0,5993
Luôn dự đoán Dương tính	0,8814	0,1579	0,0612	0,0882

Mô hình luôn dự đoán Âm tính trùng với mô hình dự đoán lớp đa số, vì lớp Âm tính là lớp đa số ở cả 14 bệnh.

2.2. Kết quả theo từng bệnh

Bảng 2.3. *Precision, recall, F1 weighted và AUROC theo lớp cho từng bệnh trên tập test (giao thức Fig. 10 và Fig. 5)*

Bệnh	n Âm / Dương / Không chắc	P w	R w	F1 w	AUROC Âm	AUROC Dương	AUROC Không chắc
No Finding	2.680 / 568 / 0	0,8418	0,8565	0,8444	0,8323	0,8323	không có
Enlarged Cardiomediastinum	2.893 / 151 / 204	0,9026	0,8907	0,8392	0,6206	0,6430	0,5915

Bệnh	n Âm / Dương / Không chắc	P w	R w	F1 w	AUROC Âm	AUROC Dương	AUROC Không chắc
Cardiomegaly (5)	2.267 / 866 / 115	0,7744	0,4951	0,4857	0,7608	0,7695	0,4994
Lung Opacity	2.131 / 1.038 / 79	0,6990	0,6167	0,6207	0,7238	0,7255	0,5612
Lung Lesion	3.107 / 123 / 18	0,9302	0,9369	0,9306	0,7419	0,7469	0,6957
Edema (5)	2.276 / 683 / 289	0,7344	0,6764	0,6895	0,8383	0,8412	0,7058
Consolidation (5)	2.931 / 220 / 97	0,8856	0,7719	0,8035	0,7296	0,7602	0,4859
Pneumonia	2.563 / 335 / 350	0,7139	0,6736	0,6805	0,7489	0,7243	0,7123
Atelectasis (5)	2.326 / 731 / 191	0,7231	0,6028	0,6152	0,7640	0,7583	0,6588
Pneumothorax	3.117 / 112 / 19	0,9530	0,9150	0,9282	0,8366	0,8531	0,7481
Pleural Effusion (5)	2.044 / 1.074 / 130	0,8129	0,7583	0,7495	0,8932	0,8925	0,6741
Pleural Other	3.169 / 63 / 16	0,9612	0,9738	0,9639	0,8095	0,8348	0,6940
Fracture	3.155 / 89 / 4	0,9722	0,9714	0,9573	0,6891	0,6849	0,7554
Support Devices	2.119 / 1.125 / 4	0,8449	0,8008	0,8051	0,9034	0,9043	0,8407

(5) đánh dấu năm bệnh của F1 năm bệnh. "không có" là lớp không có mẫu nào trong tập test nên AUROC không xác định. Fracture có 4 mẫu Không chắc chắn và Support Devices có 4 mẫu, nên AUROC lớp Không chắc của hai bệnh này rất không ổn định.

Cardiomegaly là bệnh có F1 weighted thấp nhất (0,4857). Nguyên nhân là mô hình gọi Dương tính quá nhiều ở bệnh này: recall lớp Dương tính đạt 0,9538 nhưng recall lớp Âm tính chỉ 0,3449, trong khi lớp Âm tính chiếm 2.267 trên 3.248 nghiên cứu. Ở chiều ngược lại, Enlarged Cardiomediastinum và Fracture có F1 weighted cao (lần lượt 0,8392 và 0,9573) nhưng mô hình không dự đoán Dương tính cho nghiên cứu nào của hai bệnh này (recall lớp Dương tính bằng 0,0000 và 0,0000); F1 cao chỉ phản ánh việc lớp Âm tính chiếm đa số. Vì vậy 9 trên 14 bệnh có F1 weighted trên 0,73 không có nghĩa là mô hình nhận ra tốt từng bệnh đó; AUROC theo lớp, không phụ thuộc ngưỡng, là chỉ báo đáng tin hơn về khả năng phân biệt.

2.3. Vì sao F1 weighted cao hơn bài báo khi precision và recall không cao hơn

Bảng so sánh với bài báo cho thấy một kết quả thoạt nhìn mâu thuẫn: recall weighted của mô hình tương đương bài báo, precision weighted thấp hơn, nhưng F1 weighted lại cao hơn +0,0495. Điều này không mâu thuẫn, vì F1 weighted không được tính từ precision weighted và recall weighted. Với mỗi bệnh, F1 được tính riêng cho từng lớp theo công thức $F1 = 2PR/(P + R)$, rồi lấy trung bình có trọng số theo số mẫu thật của lớp, sau đó lấy trung bình qua 14 bệnh. Precision weighted và recall weighted là các trung bình cộng nên cho phép precision cao của lớp này bù cho precision thấp của lớp kia, còn F1 là trung bình điều hòa nên chỉ cao khi precision và recall cùng cao trong cùng một lớp. Ngoài ra, recall weighted của một bệnh luôn bằng accuracy của bệnh đó, nên hai

mô hình có cùng recall weighted là hai mô hình dự đoán đúng cùng tỷ lệ mẫu; khác biệt về F1 giữa chúng chỉ đến từ cách các lỗi phân bố giữa các lớp.

Ví dụ minh họa tự dựng sau đây, không phải dữ liệu của đề tài, cho thấy cơ chế này. Một bệnh có 200 mẫu, 100 mẫu lớp A và 100 mẫu lớp B. Mô hình X chỉ dự đoán A cho 50 mẫu nó chắc chắn nhất và dự đoán B cho toàn bộ phần còn lại; mô hình Y dự đoán đúng 75 mẫu mỗi lớp và nhầm 25 mẫu mỗi lớp sang lớp kia. Cả hai đều dự đoán đúng 150 trên 200 mẫu.

Bảng 2.4. *Ví dụ minh họa tự dựng: hai mô hình có cùng recall weighted nhưng F1 weighted khác nhau*

Mô hình, lớp	Precision	Recall	F1	Trọng số
X, lớp A	1,000	0,500	0,667	0,5
X, lớp B	0,667	1,000	0,800	0,5
X, weighted	**0,833**	0,750	0,733	
Y, lớp A	0,750	0,750	0,750	0,5
Y, lớp B	0,750	0,750	0,750	0,5
Y, weighted	0,750	0,750	**0,750**	

Số liệu tự dựng để minh họa cách tính, không lấy từ tập test.

Hai mô hình có cùng recall weighted (0,750), mô hình X có precision weighted cao hơn (0,833 so với 0,750), nhưng mô hình Y có F1 weighted cao hơn (0,750 so với 0,733). Mô hình X dồn lỗi về một phía: lớp A có precision tuyệt đối nhưng recall chỉ 0,500, lớp B có recall tuyệt đối nhưng precision chỉ 0,667. Trung bình cộng che đi sự lệch này, còn F1 của từng lớp thì không. Mô hình Y phân bố lỗi đều nên precision và recall cân bằng trong từng lớp.

Số của bài báo mang dấu hiệu của kiểu mô hình X. Nếu F1 là trung bình điều hòa của precision 0,87 và recall 0,78 thì phải đạt 0,823, nhưng bài báo công bố 0,73, thấp hơn cả precision lẫn recall. Điều đó chỉ xảy ra khi trong từng bệnh có lớp precision cao nhưng recall thấp và lớp ngược lại, hoặc có lớp không bao giờ được dự đoán. Ở mô hình của đề tài, F1 weighted (0,7795) nằm giữa precision (0,8392) và recall (0,7814), tức lỗi được phân bố cân bằng hơn khi tính trung bình qua 14 bệnh. Vì bài báo không công bố độ đo theo từng lớp, nhận định về mô hình của bài báo là suy luận từ ba con số tổng hợp, không kiểm chứng trực tiếp được.

Mô hình của đề tài cũng không cân bằng ở mọi bệnh. Có 4 trên 14 bệnh mà F1 weighted thấp hơn cả precision lẫn recall weighted, gồm Enlarged Cardiomediastinum,

Cardiomegaly, Pleural Effusion và Fracture. Cardiomegaly là ví dụ rõ nhất của kiểu mô hình X trong dữ liệu thật.

Bảng 2.5. *Precision, recall và F1 theo lớp của Cardiomegaly trên tập test*

Lớp	n	Precision	Recall	F1
Âm tính	2.267	0,928	0,345	0,503
Dương tính	866	0,343	0,954	0,505
Không chắc chắn	115	1,000	0,000	0,000
Weighted		0,774	0,495	0,486

Precision 1,000 của lớp Không chắc chắn là do mô hình không dự đoán lớp này lần nào; xem đoạn dưới về zero_division.

Giao thức của bài báo tính precision bằng sklearn với zero_division bằng 1: một lớp có mẫu thật nhưng không bao giờ được dự đoán nhận precision bằng 1, recall bằng 0 và F1 bằng 0. Precision weighted vì thế được cộng một phần không phản ánh khả năng của mô hình, còn F1 thì không. Trên tập test, mô hình của đề tài có 12 cặp bệnh và lớp như vậy: lớp Không chắc chắn ở 10 bệnh, cùng lớp Dương tính của Enlarged Cardiomediastinum và Fracture. Nếu không cộng phần này (zero_division bằng 0), precision weighted trung bình 14 bệnh giảm từ 0,8392 xuống 0,8189. Precision 0,87 của bài báo cũng chứa phần cộng này nếu mô hình của họ có lớp không bao giờ được dự đoán, nhưng không xác định được có hay không và bao nhiêu vì bài báo không công bố số liệu theo lớp. Do đó chênh lệch precision giữa hai bên không nên được đọc là mô hình của đề tài kém chính xác hơn; F1 weighted, vốn không được cộng điểm khi bỏ qua một lớp, là con số đáng tin hơn trong ba con số của Fig. 10.

2.4. So sánh có ghép cặp với checkpoint trước

Hai checkpoint được chấm trên cùng 3.269 nghiên cứu (khóa nghiên cứu và nhãn được kiểm tra trùng khớp từng dòng trước khi so sánh). Khoảng tin cậy của hiệu số được ước lượng bằng bootstrap ghép cặp 1.000 lần, mỗi lần lấy mẫu lại cùng một tập chỉ số nghiên cứu cho cả hai checkpoint, hạt giống 16. Theo quy ước của đề tài, khoảng tin cậy có cận cách 0 dưới 0,0005 được coi là chưa xác lập.

Bảng 2.6. *Checkpoint mới so với run_20260930_3class trên cùng tập test, bootstrap ghép cặp*

Độ đo	Run trước	Run mới	Hiệu số	KTC 95%
Precision weighted	0,8379	0,8392	+0,0013	[-0,0047; +0,0034]
Recall weighted	0,7685	0,7814	**+0,0130**	[+0,0107; +0,0151]
F1 weighted	0,7658	0,7795	**+0,0137**	[+0,0115; +0,0157]
F1 trung bình 5 bệnh	0,6438	0,6687	**+0,0249**	[+0,0206; +0,0290]

Độ đo	Run trước	Run mới	Hiệu số	KTC 95%
macro_recall	0,4560	0,4609	**+0,0049**	[+0,0012; +0,0083]
AUROC lớp Dương	0,7755	0,7836	**+0,0081**	[+0,0035; +0,0124]
AUROC lớp Âm	0,7691	0,7780	**+0,0089**	[+0,0043; +0,0130]
AUROC lớp Không chắc	0,5737	0,6633	**+0,0896**	[+0,0413; +0,1270]

Run trước là run_20260930_3class, run mới là run_20261005_paper. Hiệu số in đậm có khoảng tin cậy nằm hoàn toàn trên 0. macro_recall là trung bình không trọng số của recall ba lớp, lấy trung bình 14 bệnh; đây là độ đo chọn epoch của đề tài, không phải độ đo của bài báo.

Checkpoint mới tốt hơn ở bảy trên tám độ đo với khoảng tin cậy nằm hoàn toàn trên 0; chỉ precision weighted là không đổi. Khác với lần so sánh run_20260930_3class với run_20260925b_3phase, trong đó hai checkpoint chỉ khác nhau trong phạm vi nhiễu, lần này các độ đo không phụ thuộc ngưỡng cũng tăng: AUROC lớp Dương tăng +0,0081, lớp Âm tăng +0,0089. Đây là dấu hiệu khả năng phân biệt thực sự tốt hơn, không chỉ là dịch chuyển điểm làm việc. Theo từng bệnh, checkpoint mới có F1 weighted cao hơn ở 10 trên 14 bệnh, AUROC lớp Dương cao hơn ở 11 trên 14 bệnh và AUROC lớp Không chắc cao hơn ở 11 trên 13 bệnh. Mức tăng lớn nhất là AUROC lớp Không chắc chắn (0,5737 lên 0,6633), nhưng khoảng tin cậy của nó rộng vì lớp này có ít mẫu. Do ba thay đổi (8 expert token, bỏ label smoothing, chọn epoch theo macro_recall) diễn ra cùng lúc, kết quả này không cho biết thay đổi nào tạo ra mức tăng.

2.5. Độ đo bổ sung ngoài giao thức của bài báo

Hai cách ra quyết định thay cho argmax được chấm thêm để đặt cạnh kết quả chính, không thay thế nó. Cách thứ nhất dùng ngưỡng riêng cho từng cặp bệnh và lớp theo phương trình (22) của bài báo (khoảng cách nhỏ nhất tới góc trên bên trái của đường ROC), ước lượng trên tập validation rồi áp dụng cho tập test; bài báo dùng các ngưỡng này để dựng prompt cho Giai đoạn 2, không dùng để báo cáo độ đo phân loại. Cách thứ hai đặt một hoặc hai điểm cắt trên điểm p_dương / (p_dương + p_âm) cho từng bệnh, ước lượng trên validation để tối đa F1 weighted.

Bảng 2.7. *Kết quả trên tập test khi thay argmax bằng các quy tắc quyết định ước lượng trên validation*

Quy tắc quyết định	P w	R w	F1 w	F1 5 bệnh	macro_recall	Số lần dự đoán Không chắc
Argmax (bài báo)	0,8392	0,7814	0,7795	0,6687	0,4609	266
Ngưỡng phương trình (22)	0,8355	0,6440	0,7017	0,6373	0,5158	không có
Một điểm cắt	0,8408	0,8388	0,8183	0,7492	0,4404	0

Quy tắc quyết định	P w	R w	F1 w	F1 5 bệnh	macro_recall	Số lần dự đoán Không chắc
Hai điểm cắt	0,8271	0,8339	0,8196	0,7491	0,4460	568

Tập test có 1.516 ô nhãn Không chắc chắn trên 14 bệnh. Số lần dự đoán Không chắc của quy tắc phương trình (22) không được script chấm điểm xuất ra nên ghi "không có".

Một điểm cắt nâng F1 năm bệnh lên 0,7492, cao hơn con số 0,701 của bài báo, và F1 weighted lên 0,8183; hiệu số so với argmax là +0,0805 cho F1 năm bệnh, khoảng tin cậy [+0,0738; +0,0869] (bootstrap ghép cặp 1.000 lần, hạt giống 16). Cái giá là macro_recall giảm và quy tắc này không bao giờ dự đoán lớp Không chắc chắn. Mức tăng đến từ việc dịch điểm cắt giữa Dương tính và Âm tính, tức là sửa xu hướng gọi Dương tính quá nhiều mà trọng số lớp đưa vào argmax. Ngưỡng phương trình (22) làm điều ngược lại: macro_recall tăng lên 0,5158 nhưng F1 weighted giảm còn 0,7017 vì recall lớp Âm tính giảm. Các quy tắc này không phải giao thức của bài báo, nên con số dùng để so với bài báo vẫn là dòng argmax.

2.6. Kết quả trên validation và quá trình chọn epoch

Bảng 2.8. *Độ đo trên validation ở từng epoch của pha 1b và ở pha 1c, n = 1.808 nghiên cứu*

Epoch	macro_recall	F1 w	F1 5 bệnh	AUROC Dương	AUROC Không chắc
1b, epoch 0	0,4775	0,8299	0,7470	0,7955	0,6806
1b, epoch 1	0,4883	0,8222	0,7314	0,8052	0,6796
1b, epoch 2 (chọn)	**0,4919**	0,8236	0,7377	0,8112	0,7097
1b, epoch 3	0,4916	0,8219	0,7386	0,8122	0,7009
1b, epoch 4	0,4911	0,8184	0,7326	0,8123	0,6929
1c, epoch 0	0,4856	0,8285	0,7488	0,8095	0,6928

Trên validation, F1 năm bệnh của checkpoint cuối là 0,7488, cao hơn 0,701 của bài báo, trong khi trên test chỉ đạt 0,6687. Khoảng cách 0,0801 giữa hai tập lớn hơn nhiều so với sai khác giữa các epoch, nên không thể dùng số trên validation để khẳng định mô hình đạt hoặc vượt bài báo. Pha 1c làm macro_recall trên validation giảm nhẹ so với epoch được chọn của pha 1b (0,4856 so với 0,4919), phù hợp với ghi nhận trước đây rằng pha 1c hầu như không thay đổi phần phân loại.

CHƯƠNG 3. THẢO LUẬN VÀ GIỚI HẠN

Điểm yếu rõ nhất của mô hình vẫn là lớp Không chắc chắn. Với argmax, mô hình chỉ dự đoán lớp này 266 lần cho 1.516 ô nhãn Không chắc chắn, recall 0,0317 và

precision 0,1805, nên macro_recall chỉ đạt 0,4609 so với mức ngẫu nhiên 0,3333. Các độ đo weighted của bài báo che khuất điểm yếu này vì lớp Không chắc chắn chiếm tỷ lệ nhỏ trong trọng số. AUROC lớp Không chắc đã tăng rõ so với checkpoint trước nhưng vẫn thấp hơn nhiều so với hai lớp còn lại.

Có bốn giới hạn khi đặt các con số này cạnh bài báo. Thứ nhất, bài báo không công bố danh sách nghiên cứu của tập test, nên chênh lệch có thể một phần do khác tập dữ liệu. Thứ hai, code tham chiếu của bài báo lấy trung bình độ đo theo batch, còn đề tài tính trên toàn bộ tập test. Thứ ba, đề tài chỉ huấn luyện một lần với một hạt giống, nên khoảng tin cậy chỉ phản ánh biến thiên do lấy mẫu dữ liệu, không phản ánh biến thiên do huấn luyện. Thứ tư, hai độ đo phân loại khác của bài báo chưa tính được: F1 liên miền trên CheXpert validation (Bảng 4, 0,699) vì repo chưa có bộ nạp tập này cho Giai đoạn 1, và Clinical Efficacy (Bảng 3) vì repo chưa có bộ gán nhãn CheXpert cho báo cáo sinh ra; cả hai được ghi là không có, không phải bằng 0.

CHƯƠNG 4. KẾT LUẬN

Theo đúng giao thức của bài báo, checkpoint run_20261005_paper đạt F1 weighted 0,7795, cao hơn con số 0,73 của bài báo, recall 0,7814 tương đương 0,78, còn precision 0,8392 và F1 năm bệnh 0,6687 thấp hơn 0,87 và 0,701. So với checkpoint trước trên cùng tập test, checkpoint mới tốt hơn có ý nghĩa thống kê ở bảy trên tám độ đo, kể cả các độ đo AUROC không phụ thuộc ngưỡng, nên đây là checkpoint Giai đoạn 1 tốt nhất hiện có theo giao thức ba lớp và là checkpoint đang được dùng cho lượt huấn luyện Giai đoạn 2 theo cấu hình của bài báo. Khoảng cách còn lại so với bài báo ở F1 năm bệnh nằm chủ yếu ở cách ra quyết định: khi điểm cắt giữa Dương tính và Âm tính được ước lượng trên validation, F1 năm bệnh vượt 0,701, nhưng kết quả đó nằm ngoài giao thức của bài báo và chỉ được báo cáo như số bổ sung.

TÀI LIỆU THAM KHẢO

[1] D. Edirisinghe, W. Nimalsiri, M. Hennayake, D. Meedeniya, and G. Lim, "Chest X-ray report generation using abnormality guided vision language model," IEEE Access, vol. 13, pp. 157651-157673, 2025, doi: 10.1109/ACCESS.2025.3606961.

[2] J. Irvin et al., "CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison," in Proc. AAAI Conf. Artif. Intell., vol. 33, 2019, pp. 590-597.

[3] A. E. W. Johnson et al., "MIMIC-CXR-JPG, a large publicly available database of labeled chest radiographs," arXiv:1901.07042, 2019.