KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ HỆ THỐNG META-CXR TRÊN BỘ DỮ LIỆU MIMIC-CXR-JPG

Tài liệu này trình bày toàn bộ kết quả đánh giá của hệ thống sinh báo cáo X-quang ngực hai giai đoạn được xây dựng trong đề tài, dựa trên nhánh mã nguồn chính (main, revision 79139fc). Giai đoạn 1 phân loại 14 nhãn bất thường; Giai đoạn 2 sinh phần FINDINGS của báo cáo. Mọi số liệu Giai đoạn 1 được tính lại từ tệp dự đoán đã lưu và tái lập chính xác đến bốn chữ số thập phân; mọi số liệu Giai đoạn 2 trên tập kiểm tra được sinh lại sau khi sửa lỗi điều kiện dừng sinh và được chấm lại theo giao thức chuẩn của lĩnh vực để có thể đặt cạnh các công trình đã công bố. Các thử nghiệm huấn luyện gần nhất không cải thiện kết quả chỉ được đưa vào như nghiên cứu cắt bỏ, không thay thế mô hình chính.

CHƯƠNG 1. BỘ DỮ LIỆU VÀ THIẾT LẬP THỰC NGHIỆM

1.1. Bộ dữ liệu MIMIC-CXR-JPG

1.1.1. Nguồn gốc và quan hệ với MIMIC-CXR

Toàn bộ thực nghiệm sử dụng MIMIC-CXR-JPG phiên bản 2.1.0 [1], bộ ảnh X-quang ngực định dạng JPG được dẫn xuất từ cơ sở dữ liệu MIMIC-CXR [2]. Bộ dữ liệu gồm 377.110 ảnh thuộc 227.835 nghiên cứu của 65.379 bệnh nhân, trong đó mỗi nghiên cứu (study) ứng với một lần chụp, một báo cáo văn bản, và có thể gồm nhiều ảnh ở các tư thế khác nhau. Đi kèm là nhãn có cấu trúc do bộ gán nhãn CheXpert [3] trích xuất tự động từ văn bản báo cáo, với bốn trạng thái cho mỗi bệnh lý: dương tính (1), âm tính (0), không chắc chắn (-1) và để trống khi báo cáo không nhắc tới bệnh lý đó.

Theo trang mô tả chính thức [1], MIMIC-CXR-JPG sử dụng chính tệp phân chia chính thức mimic-cxr-2.0.0-split.csv.gz của MIMIC-CXR. Hệ quả quan trọng cho việc so sánh là các công trình sinh báo cáo đánh giá trên tập kiểm tra theo phân chia chính thức của MIMIC-CXR đang chấm trên cùng tập nghiên cứu và cùng văn bản báo cáo với đề tài này; khác biệt nằm ở định dạng lưu ảnh (DICOM so với JPG) chứ không ở tập dữ liệu đánh giá. Điều này thể hiện trực tiếp qua số lượng: công trình R2Gen [5] báo cáo tập kiểm định và kiểm tra gồm 1.808 và 3.269 báo cáo, trùng khớp về số lượng với 1.808 và 3.269 nghiên cứu trong tập đánh giá Giai đoạn 1 của đề tài. Sự trùng khớp về số lượng là

bằng chứng mạnh nhưng không phải phép kiểm tra đồng nhất từng nghiên cứu, vì các công trình đó không công bố danh sách định danh.

1.1.2. Thống kê dữ liệu đầu vào

Dữ liệu đầu vào gồm ba tệp siêu dữ liệu đi kèm MIMIC-CXR-JPG và cây thư mục báo cáo văn bản của MIMIC-CXR. Tệp metadata mô tả từng ảnh (tư thế chụp, kích thước), tệp split gán mỗi ảnh vào một tập theo phân chia chính thức, và tệp chexpert chứa nhãn 14 bệnh lý ở mức nghiên cứu. Bảng dưới đây thống kê các nguồn này trước mọi bước lọc.

Bảng 1.1. *Thống kê dữ liệu thô của MIMIC-CXR-JPG trước tiền xử lý*

Đại lượng	Giá trị
Số ảnh trong tệp metadata	377.110
Số nghiên cứu (lần chụp)	227.835
Số bệnh nhân	65.379
Số nghiên cứu có bản ghi nhãn CheXpert	227.827
Số bản ghi nhãn để trống toàn bộ 14 bệnh lý	2.414
Tỉ lệ ô nhãn để trống trong ma trận CheXpert	79,4%
Số ảnh có cạnh nhỏ hơn 100 điểm ảnh	0
Chiều cao ảnh, trung vị (khoảng 5% đến 95%)	3.050 (2.021 đến 3.056) điểm ảnh
Chiều rộng ảnh, trung vị (khoảng 5% đến 95%)	2.544 (1.736 đến 3.056) điểm ảnh

Bảng 1.2. *Phân bố tư thế chụp trên toàn bộ ảnh*

Tư thế chụp	Số ảnh	Tỉ lệ
AP	147.173	39,0%
PA	96.161	25,5%
LATERAL	82.853	22,0%
LL	35.133	9,3%
UNKNOWN	15.769	4,2%
Tư thế hiếm khác (10 loại)	21	0,0%

PA: sau trước; AP: trước sau; LATERAL và LL: nghiêng; UNKNOWN: không ghi tư thế trong siêu dữ liệu. Tư thế hiếm được mô hình xếp chung nhóm không rõ tư thế.

1.1.3. Quy trình tiền xử lý

Tiền xử lý được thực hiện bằng tập lệnh preporcessing/preprocess_mimic_cxr.py, chạy trên CPU và không đọc ảnh, tạo ra bộ manifest full_allviews_v2 gồm ba tệp train, val và test. Quy trình gồm bảy bước.

Bước 1, làm sạch nhãn: kiểm tra mỗi cặp bệnh nhân và nghiên cứu chỉ có một bản ghi nhãn, giữ lại cả nghiên cứu không có nhãn nào và đánh dấu bằng cờ has_chexpert_label. Bước 2, làm sạch siêu dữ liệu: loại dòng trùng lặp hoàn toàn, kiểm

tra tính duy nhất theo mã ảnh, loại ảnh có cạnh nhỏ hơn 100 điểm ảnh, và gán tư thế UNKNOWN cho ảnh không ghi tư thế thay vì loại bỏ. Bước 3, làm sạch phân chia: chuẩn hóa tên tập và kiểm tra rằng không bệnh nhân nào và không nghiên cứu nào xuất hiện ở hai tập. Bước 4, ghép ba nguồn theo khóa bệnh nhân, nghiên cứu và ảnh với ràng buộc một đối một, để phép ghép không thể nhân bản dòng một cách âm thầm.

Bước 5, trích xuất văn bản: đọc báo cáo của từng nghiên cứu, làm sạch và tách phần FINDINGS và IMPRESSION bằng bộ phân tích mimic_report_parser.py. Khi báo cáo không có tiêu đề FINDINGS, bộ phân tích khôi phục phần tường thuật thay vì lấy cả báo cáo, và không bao giờ dùng IMPRESSION để thay cho FINDINGS. Bước 6, lọc độ dài: đếm số token từ vựng của FINDINGS, đánh dấu không hợp lệ các báo cáo dưới 3 token hoặc vượt phân vị 99% độ dài của tập huấn luyện; ngưỡng trên chỉ được tính từ tập huấn luyện để tập kiểm tra không ảnh hưởng tới quy trình. IMPRESSION được lọc riêng theo phân phối độ dài của chính nó. Báo cáo không hợp lệ bị xóa trắng văn bản đích nhưng nghiên cứu vẫn được giữ lại cho bài toán phân loại. Bước 7, sinh đường dẫn ảnh tương đối và ghi ba tệp manifest.

Bảng 1.3. *Các tham số và quy tắc lọc của quy trình tiền xử lý*

Quy tắc	Giá trị	Hệ quả
Tư thế chụp được giữ	Tất cả	Phục vụ hợp nhất nhiều góc nhìn
Kích thước ảnh tối thiểu	100 điểm ảnh mỗi cạnh	Loại 0 ảnh
Số token FINDINGS tối thiểu	3	Nhãn lọc TOO_SHORT
Số token FINDINGS tối đa	Phân vị 99% của tập huấn luyện	Nhãn lọc TOO_LONG
Không trích được FINDINGS	Không áp dụng	Nhãn lọc NO_FINDINGS
Nghiên cứu không có nhãn	Giữ lại	Bị che khỏi hàm mất mát phân loại
Ô nhãn để trống	Giữ giá trị bỏ qua (-100)	Không bị coi là âm tính
Phân chia dữ liệu	Tệp split chính thức	Không tự chia lại

1.1.4. Phân chia tập huấn luyện, kiểm định và kiểm tra

Đề tài không tự chia dữ liệu mà dùng nguyên phân chia chính thức của MIMIC-CXR, trong đó mỗi bệnh nhân chỉ thuộc một tập. Phép kiểm tra trên manifest sau tiền xử lý cho kết quả 0 bệnh nhân và 0 nghiên cứu xuất hiện ở hơn một tập, và 0 mã ảnh bị trùng. Tổng cộng manifest có 377.110 ảnh thuộc 227.835 nghiên cứu. Tỉ lệ các tập rất lệch về phía huấn luyện, là đặc điểm của phân chia chính thức: tập kiểm định và kiểm tra nhỏ, nên các khoảng tin cậy trong tài liệu được ước lượng bằng bootstrap thay vì dựa vào một điểm số.

Bảng 1.4. *Số lượng bệnh nhân, nghiên cứu và ảnh theo từng tập*

Tập	Bệnh nhân	Nghiên cứu	Tỉ lệ nghiên cứu	Ảnh	Ảnh trên nghiên cứu	Nghiên cứu có nhãn
Huấn luyện	64.586	222.758	97,8%	368.960	1,66	220.379
Kiểm định	500	1.808	0,8%	2.991	1,65	1.786
Kiểm tra	293	3.269	1,4%	5.159	1,58	3.248
Tổng	**65.379**	**227.835**	**100,0%**	**377.110**	**1,66**	**225.413**

Bảng 1.5. *Phân bố tư thế chụp theo ảnh trong từng tập*

Tập	PA	AP	Nghiêng	Không rõ hoặc hiếm
Huấn luyện	94.416	143.556	115.647	15.341
Kiểm định	747	1.212	908	124
Kiểm tra	998	2.405	1.431	325

Mô hình Giai đoạn 1 lấy mẫu theo nghiên cứu: mỗi nghiên cứu chọn một ảnh chính theo thứ tự ưu tiên PA, AP, nghiêng, và tối đa một ảnh phụ có tư thế khác ảnh chính. Ảnh chụp lặp lại cùng tư thế không được dùng làm ảnh phụ vì không bổ sung góc nhìn mới. Bảng sau cho thấy số nghiên cứu có ảnh phụ thực sự, tức là số nghiên cứu mà mô-đun hợp nhất góc nhìn có dữ liệu để hoạt động.

Bảng 1.6. *Ảnh chính, ảnh phụ và số ảnh trên mỗi nghiên cứu*

Tập	Ảnh chính PA	Ảnh chính AP	Ảnh chính nghiêng	Ảnh chính không rõ	Nghiên cứu nhiều ảnh	Có ảnh phụ khác tư thế	Số ảnh, trung vị
Huấn luyện	84.328	129.037	2.332	7.061	122.660	105.462 (47,3%)	2 (tối đa 11)
Kiểm định	661	1.072	19	56	973	820 (45,4%)	2 (tối đa 4)
Kiểm tra	883	2.158	50	178	1.527	1.247 (38,1%)	1 (tối đa 5)

1.1.5. Thống kê văn bản báo cáo

Mục tiêu sinh của Giai đoạn 2 là phần FINDINGS. Bảng dưới đây thống kê kết quả trích xuất và lọc độ dài ở mức nghiên cứu. Nhóm hợp lệ là các nghiên cứu có báo cáo tham chiếu dùng để huấn luyện và chấm điểm sinh báo cáo.

Bảng 1.7. *Kết quả lọc phần FINDINGS và IMPRESSION theo nghiên cứu*

Tập	Nghiên cứu	FINDINGS hợp lệ	Không có FINDINGS	Quá ngắn	Quá dài	IMPRESSION hợp lệ	Có cả hai
Huấn luyện	222.758	176.312 (79,1%)	44.554	158	1.734	183.770	138.487
Kiểm định	1.808	1.415 (78,3%)	379	4	10	1.505	1.119
Kiểm tra	3.269	2.984 (91,3%)	228	6	51	2.177	1.920

Bảng 1.8. *Độ dài phần FINDINGS và IMPRESSION hợp lệ, tính bằng số token từ vựng*

Tập	Phần báo cáo	Số nghiên cứu	Trung bình	Trung vị	Khoảng 5% đến 95%	Tối đa
Huấn luyện	FINDINGS	176.312	54,5	51	17 đến 101	147
Huấn luyện	IMPRESSION	183.770	28,1	20	5 đến 78	116
Kiểm định	FINDINGS	1.415	54,4	52	12 đến 102	146
Kiểm định	IMPRESSION	1.505	29,7	22	5 đến 80	116
Kiểm tra	FINDINGS	2.984	64,5	63	9 đến 116	147
Kiểm tra	IMPRESSION	2.177	30,6	23	5 đến 84	116

Bảng 1.9. *Cách trích xuất văn bản đích theo từng tập (số nghiên cứu)*

Phương thức	Ý nghĩa	Huấn luyện	Kiểm định	Kiểm tra
FINDINGS_TAG	Có tiêu đề FINDINGS, lấy trực tiếp	146.416	1.140	2.143
IMPRESSION_ONLY	Chỉ có IMPRESSION, không tạo đích FINDINGS	44.394	377	222
NARRATIVE_BODY	Không có tiêu đề, khôi phục phần tường thuật	31.748	287	898
FINDINGS_IMPRESSION_COMBINED	FINDINGS và IMPRESSION viết gộp	135	2	6
NARRATIVE_AFTER_COMPARISON	Tường thuật nằm sau mục so sánh	40	2	0
NO_FINDINGS	Không trích được nội dung	25	0	0

Tên phương thức là giá trị cột extraction_method do bộ phân tích báo cáo ghi lại.

Trên tập huấn luyện, 8.298 nghiên cứu có FINDINGS hợp lệ nhưng không quá 15 token, chiếm 4,7% số báo cáo đích hợp lệ. Đây là các báo cáo một dòng, phần lớn mô tả kỹ thuật chụp; chúng vượt qua ngưỡng tối thiểu 3 token nên vẫn được dùng làm mục tiêu sinh, và được ghi nhận như một hạn chế của dữ liệu.

Ba tập không đồng nhất về phân phối, và điều này cần được lưu ý khi so sánh kết quả kiểm định với kiểm tra. Tập kiểm tra chỉ gồm 293 bệnh nhân cho 3.269 nghiên cứu, trung bình 11,2 nghiên cứu mỗi bệnh nhân, so với 3,4 ở tập huấn luyện và 3,6 ở tập kiểm định; các nghiên cứu của cùng một bệnh nhân tương quan với nhau, nên bootstrap theo nghiên cứu có thể cho khoảng tin cậy hẹp hơn thực tế. Tỉ lệ ảnh chính chụp tư thế AP, thường gặp ở bệnh nhân nằm tại giường, là 66,0% ở tập kiểm tra so với 57,9% ở tập huấn luyện. Trung vị độ dài FINDINGS hợp lệ của tập kiểm tra là 63 token, dài hơn 51 token của tập huấn luyện, và tỉ lệ ô nhãn để trống thấp hơn (76,4% so với 79,5%). Các khác biệt này gợi ý tập kiểm tra chứa nhiều ca có nhiều phát hiện được mô tả hơn, nhưng đề tài không có dữ liệu lâm sàng để kiểm chứng mức độ nặng.

1.1.6. Thống kê nhãn theo từng bệnh lý

Nhãn CheXpert có bốn trạng thái: dương tính (P), âm tính (N), không chắc chắn (U) và để trống khi báo cáo không nhắc tới bệnh lý. Ba bảng dưới đây đếm số nghiên cứu

theo từng trạng thái cho mỗi nhãn và mỗi tập. Cột tỉ lệ hiện diện là số nghiên cứu dương tính chia cho tổng số nghiên cứu của tập, tương ứng với cách diễn giải study_presence dùng để báo cáo F1; cột tỉ lệ dương tính khi được nhắc là P chia cho tổng P, N và U, tương ứng với cách diễn giải masked_polarity mà hàm mất mát phân loại sử dụng.

Bảng 1.10. *Phân bố nhãn P, N, U và để trống trên tập huấn luyện (222.758 nghiên cứu)*

Bệnh lý	P	N	U	Để trống	Tỉ lệ hiện diện	Tỉ lệ P khi được nhắc
Không có bất thường (No Finding)	74.305	0	0	148.453	33,4%	100,0%
Giãn trung thất (Enlarged Cardiomediastinum)	6.968	5.168	9.083	201.539	3,1%	32,8%
Tim to (Cardiomegaly)	43.602	15.613	5.869	157.674	19,6%	67,0%
Mờ phổi (Lung Opacity)	50.099	2.993	3.726	165.940	22,5%	88,2%
Tổn thương phổi (Lung Lesion)	6.091	841	1.114	214.712	2,7%	75,7%
Phù phổi (Edema)	26.093	25.133	12.777	158.755	11,7%	40,8%
Đông đặc (Consolidation)	10.476	7.817	4.186	200.279	4,7%	46,6%
Viêm phổi (Pneumonia)	16.093	23.904	17.797	164.964	7,2%	27,8%
Xẹp phổi (Atelectasis)	44.718	1.502	10.041	166.497	20,1%	79,5%
Tràn khí màng phổi (Pneumothorax)	10.171	41.271	1.106	170.210	4,6%	19,4%
Tràn dịch màng phổi (Pleural Effusion)	52.759	26.615	5.639	137.745	23,7%	62,1%
Bất thường màng phổi khác (Pleural Other)	1.933	126	743	219.956	0,9%	69,0%
Gãy xương (Fracture)	4.283	877	548	217.050	1,9%	75,0%
Thiết bị hỗ trợ (Support Devices)	64.868	3.422	230	154.238	29,1%	94,7%

2.379 nghiên cứu của tập này không có bản ghi nhãn và được tính vào cột để trống.

Bảng 1.11. *Phân bố nhãn P, N, U và để trống trên tập kiểm định (1.808 nghiên cứu)*

Bệnh lý	P	N	U	Để trống	Tỉ lệ hiện diện	Tỉ lệ P khi được nhắc
Không có bất thường (No Finding)	582	0	0	1.226	32,2%	100,0%
Giãn trung thất (Enlarged Cardiomediastinum)	60	51	88	1.609	3,3%	30,2%
Tim to (Cardiomegaly)	377	124	59	1.248	20,9%	67,3%
Mờ phổi (Lung Opacity)	388	18	26	1.376	21,5%	89,8%
Tổn thương phổi (Lung Lesion)	70	7	9	1.722	3,9%	81,4%
Phù phổi (Edema)	242	203	108	1.255	13,4%	43,8%
Đông đặc (Consolidation)	82	55	48	1.623	4,5%	44,3%
Viêm phổi (Pneumonia)	128	166	144	1.370	7,1%	29,2%
Xẹp phổi (Atelectasis)	359	9	95	1.345	19,9%	77,5%
Tràn khí màng phổi (Pneumothorax)	75	358	9	1.366	4,1%	17,0%
Tràn dịch màng phổi (Pleural Effusion)	467	203	45	1.093	25,8%	65,3%
Bất thường màng phổi khác (Pleural Other)	15	0	6	1.787	0,8%	71,4%
Gãy xương (Fracture)	18	6	3	1.781	1,0%	66,7%
Thiết bị hỗ trợ (Support Devices)	565	30	3	1.210	31,2%	94,5%

22 nghiên cứu của tập này không có bản ghi nhãn và được tính vào cột để trống.

Bảng 1.12. *Phân bố nhãn P, N, U và để trống trên tập kiểm tra (3.269 nghiên cứu)*

Bệnh lý	P	N	U	Để trống	Tỉ lệ hiện diện	Tỉ lệ P khi được nhắc
Không có bất thường (No Finding)	568	0	0	2.701	17,4%	100,0%
Giãn trung thất (Enlarged Cardiomediastinum)	151	64	204	2.850	4,6%	36,0%

Bệnh lý	P	N	U	Để trống	Tỉ lệ hiện diện	Tỉ lệ P khi được nhắc
Tim to (Cardiomegaly)	866	174	115	2.114	26,5%	75,0%
Mờ phổi (Lung Opacity)	1.038	58	79	2.094	31,8%	88,3%
Tổn thương phổi (Lung Lesion)	123	14	18	3.114	3,8%	79,4%
Phù phổi (Edema)	683	305	289	1.992	20,9%	53,5%
Đông đặc (Consolidation)	220	95	97	2.857	6,7%	53,4%
Viêm phổi (Pneumonia)	335	268	350	2.316	10,2%	35,2%
Xẹp phổi (Atelectasis)	731	20	191	2.327	22,4%	77,6%
Tràn khí màng phổi (Pneumothorax)	112	727	19	2.411	3,4%	13,1%
Tràn dịch màng phổi (Pleural Effusion)	1.074	340	130	1.725	32,9%	69,6%
Bất thường màng phổi khác (Pleural Other)	63	0	16	3.190	1,9%	79,7%
Gãy xương (Fracture)	89	3	4	3.173	2,7%	92,7%
Thiết bị hỗ trợ (Support Devices)	1.125	34	4	2.106	34,4%	96,7%

21 nghiên cứu của tập này không có bản ghi nhãn và được tính vào cột để trống.

Bảng 1.13. *Mức độ thưa của ma trận nhãn*

Tập	Tỉ lệ ô để trống	Số nhãn được nhắc trên nghiên cứu	Số nhãn dương tính trên nghiên cứu	Nghiên cứu chỉ có nhãn No Finding
Huấn luyện	79,5%	2,88	1,85	49.760
Kiểm định	79,1%	2,93	1,90	388
Kiểm tra	76,4%	3,30	2,20	336

Ba đặc điểm của phân bố nhãn quyết định cách thiết kế hàm mất mát và độ đo. Thứ nhất, ma trận rất thưa: 79,5% ô trên tập huấn luyện để trống, mỗi nghiên cứu trung bình chỉ có 2,88 trên 14 nhãn được nhắc tới. Thứ hai, khi chỉ xét các ô được nhắc, mất cân bằng bị đảo ngược so với trực giác: 12 trên 14 bệnh lý có số ô dương tính nhiều hơn âm tính trên tập huấn luyện, ví dụ Atelectasis có 44.718 ô dương tính so với 1.502 ô âm tính, phù hợp với việc báo cáo thường chỉ nhắc tới một bệnh lý khi có dấu hiệu của nó. Đây là lý do F1 dưới cách diễn giải masked_polarity bị thổi phồng và đề tài chỉ báo cáo F1 dưới study_presence. Thứ ba, một số nhãn suy biến: No Finding không bao giờ có giá trị âm tính (0 ô N trên tập kiểm tra), Pleural Other có 63 P và 0 N, Fracture có 89 P và 3 N trên tập kiểm tra, và nhãn hiếm nhất trên tập kiểm tra là Pleural Other với 63 nghiên cứu dương tính. Các nhãn này được diễn giải thận trọng trong bảng kết quả từng nhãn.

1.1.7. Xử lý ảnh và nhãn khi huấn luyện

Ảnh JPG được đọc dưới dạng thang xám, thu nhỏ cạnh ngắn về 512 điểm ảnh và giữ tỉ lệ, sau đó cắt vùng trung tâm 448 nhân 448 và nhân bản thành ba kênh. BioViL-T nhận ảnh 448 và tạo lưới 14 nhân 14 token; PubMedCLIP nhận bản thu nhỏ 224 của cùng vùng cắt, nên hai bộ mã hóa dùng chung một hệ tọa độ. Tăng cường dữ liệu chỉ áp dụng cho tập huấn luyện; ảnh chính và ảnh phụ của một nghiên cứu được biến đổi ngẫu nhiên

độc lập với nhau. Tập kiểm định và kiểm tra chỉ qua thu nhỏ và cắt trung tâm. Giai đoạn 2 dùng bộ xử lý ảnh gốc của MedGemma, đưa ảnh về 896 nhân 896 không giữ tỉ lệ và không cắt.

Bảng 1.14. *Các phép biến đổi ảnh*

Phép biến đổi	Tham số	Áp dụng cho
Thu nhỏ cạnh ngắn	512 điểm ảnh, giữ tỉ lệ	Mọi tập, Giai đoạn 1
Cắt trung tâm	448 nhân 448	Mọi tập, Giai đoạn 1
Biến đổi affine ngẫu nhiên	Xoay 5 độ, tịnh tiến 2%, co giãn 5%, xác suất 0,5	Tập huấn luyện
Thay đổi độ sáng và tương phản	Biên độ 0,1, xác suất 0,5	Tập huấn luyện
Bộ xử lý ảnh MedGemma	896 nhân 896, không giữ tỉ lệ	Mọi tập, Giai đoạn 2

Nhãn được ánh xạ thành ba mục tiêu khác nhau tùy mục đích. Bảng sau tóm tắt cách một ô nhãn gốc được chuyển thành mục tiêu của đầu phân loại, mục tiêu của cổng nhắc tới, và nhãn dùng khi đánh giá.

Bảng 1.15. *Ánh xạ nhãn CheXpert thành mục tiêu huấn luyện và đánh giá*

Giá trị gốc	Đầu phân loại P/N/U	Cổng nhắc tới	Đánh giá study_presence
1 (dương tính)	Lớp dương tính	1	Có bệnh
0 (âm tính)	Lớp âm tính	1	Không có bệnh
-1 (không chắc chắn)	Lớp không chắc chắn	1	Không có bệnh
Để trống	Bỏ qua (-100), không tính mất mát	0	Không có bệnh
Nghiên cứu không có bản ghi nhãn	Bỏ qua toàn bộ	Bỏ qua toàn bộ	Không có bệnh

1.1.8. Vai trò của các tập trong thực nghiệm

Bảng 1.16. *Vai trò của các tập dữ liệu*

Tập	Số nghiên cứu	Vai trò
Huấn luyện	222.758	Huấn luyện Giai đoạn 1
Huấn luyện, có FINDINGS hợp lệ	176.312	Huấn luyện Giai đoạn 2
Kiểm định	1.808	Chọn checkpoint, hiệu chuẩn ngưỡng quyết định
Kiểm tra	3.269	Báo cáo kết quả, chỉ dùng một lần sau khi đã cố định mô hình

Số nghiên cứu huấn luyện Giai đoạn 2 lấy từ tệp manifest của adapter đã huấn luyện.

1.1.9. Các tập đánh giá

Mỗi phép so sánh trong tài liệu được thực hiện trên đúng một tập nghiên cứu cố định, và danh sách định danh băm (sample_key) của các hệ thống được kiểm tra trùng

khớp cả về tập hợp lẫn thứ tự trước khi tính điểm. Tập kiểm tra của Giai đoạn 2 nhỏ hơn Giai đoạn 1 vì hai lý do: chỉ các nghiên cứu có phần FINDINGS hợp lệ mới có báo cáo tham chiếu, và hệ thống kết hợp đọc dữ liệu qua đường Giai đoạn 1 trong khi hai hệ thống còn lại đọc qua manifest ảnh thẳng; tập 2.772 nghiên cứu là giao của hai đường này.

Bảng 1.17. *Các tập nghiên cứu dùng để đánh giá*

Giai đoạn	Tập	Số nghiên cứu	Mục đích
1	Kiểm định	1.808	Hiệu chuẩn ngưỡng quyết định
1	Kiểm tra	3.269	Kết quả chính và nghiên cứu cắt bỏ
2	Kiểm tra	2.772	Kết quả chính của ba hệ thống
2	Kiểm định	300	Cắt bỏ kênh gợi ý, token phát hiện, đối Giai đoạn 1
2	Kiểm định	100	Cắt bỏ quy tắc tạo gợi ý
2	Kiểm định	25	Thí nghiệm lỗi điều kiện dừng sinh

1.2. Môi trường thực nghiệm

Bảng 1.18. *Phần cứng và phần mềm*

Thành phần	Cấu hình
GPU	Một NVIDIA GeForce RTX 5060 Ti, 16 GB (15,48 GiB khả dụng cho PyTorch)
Hệ điều hành	Ubuntu 26.04 LTS
Python và PyTorch	Python 3.11.16; PyTorch 2.9.1 với CUDA 12.9
Thư viện mô hình	transformers 4.53.2; PEFT; bitsandbytes
Chấm điểm sinh báo cáo	pycocoevalcap 1.2 (METEOR 1.5 chạy trên OpenJDK 25); bert_score 0.3.12

1.3. Cấu hình huấn luyện

Giai đoạn 1 huấn luyện một lần theo cấu hình được trích trực tiếp từ nhật ký của lần chạy (run_20260820_ft), không lấy từ tệp cấu hình hiện hành, để bảng dưới đây mô tả đúng mô hình đã được đánh giá.

Bảng 1.19. *Siêu tham số huấn luyện Giai đoạn 1*

Siêu tham số	Giá trị
Kích thước lô	16 nghiên cứu, tích lũy gradient 4 bước (lô hiệu dụng 64)
Tốc độ học	0.0001 cho mô-đun huấn luyện; 1e-05 cho phần bộ mã hóa được mở khóa; tối thiểu 2e-05
Lịch tốc độ học	Khởi động tuyến tính 800 bước cập nhật, sau đó cosine
Số epoch	10; bắt đầu chấm kiểm định từ epoch thứ 5
Suy giảm trọng số	0,02
Độ chính xác số	Hỗn hợp bfloat16
Tiêu chí chọn checkpoint	Hàm mất mát trên tập kiểm định; checkpoint tốt nhất là epoch 9

Siêu tham số	Giá trị
Bộ mã hóa ảnh	BioViL-T (ResNet-50, ảnh 448, 196 token) và PubMedCLIP (ViT-B/32, ảnh 224, 50 token)
Mở khóa bộ mã hóa	unfroze 69 parameters (31,85M) across 5 patterns; batchnorm_eval=True
Thời gian huấn luyện	15:31:20 (giờ:phút:giây)
Bộ nhớ GPU cực đại	8.976 MiB

Bảng 1.20. *Trọng số các thành phần hàm mất mát Giai đoạn 1*

Thành phần	Trọng số	Vai trò
Phân loại học viên (student)	1,00	Phân loại 14 nhãn, 3 lớp, chỉ từ ảnh
Phân loại giáo viên (teacher)	0,50	Giáo viên đọc thêm văn bản báo cáo, chỉ khi huấn luyện
Chưng cất tri thức	0,50	Truyền phân bố của giáo viên sang học viên
Cổng nhắc tới (mention gate)	0,50	Dự đoán báo cáo có nhắc tới bệnh lý hay không
Tương phản MHCAC	0,30	Tách biệt biểu diễn các bệnh lý
Trực giao	0,70	Giảm dư thừa giữa các đầu chú ý
Thưa	0,30	Làm thưa bản đồ chú ý
Tương phản đa dương tính	0,02	Nhất quán giữa các góc nhìn của một nghiên cứu
Nhất quán góc nhìn	0,05	Ràng buộc mềm giữa dự đoán hợp nhất và ảnh chính
ITC, ITM, LM của Q-Former	0,00	Tắt; bốn lần đo độc lập đều ở mức ngẫu nhiên (Mục 2.6)
Giải thích (Grad-CAM)	0,00	Tắt; thử nghiệm có đối chứng không cải thiện (Mục 2.6)

Bảng 1.21. *Siêu tham số huấn luyện Giai đoạn 2*

Siêu tham số	Hệ thống A (ảnh gốc)	Hệ thống C (kết hợp)
Mô hình ngôn ngữ	MedGemma 1.5 4B-it	MedGemma 1.5 4B-it
Lượng tử hóa và tinh chỉnh	NF4 4-bit, QLoRA r=16, alpha=32	NF4 4-bit, QLoRA r=16, alpha=32
Đầu vào thị giác	Tháp ảnh của MedGemma	Tháp ảnh của MedGemma, 32 token mềm Q-Former, gợi ý P/N/U
Lô hiệu dụng	16 (2 x 8)	16 (2 x 8)
Tốc độ học LoRA	0.0001	0.0001
Tốc độ học bộ chiếu	không áp dụng	0.001
Độ dài chuỗi tối đa	768	768
Tham số huấn luyện được	29.802.496	31.771.136
Mức hoàn thành	0,8621 epoch (dừng do tắt máy theo lịch)	1 epoch đầy đủ
Chọn checkpoint	Không có (checkpoint cuối cùng)	Hàm mất mát kiểm định, tốt nhất 1,0019

Hệ thống A dừng ở 9.500 trên 11.020 bước cập nhật và chưa từng chạy kiểm định, nên mọi kết quả của hệ thống A phải được hiểu là kết quả của 0,86 epoch.

1.4. Nguyên tắc đánh giá

Năm nguyên tắc áp dụng cho mọi số liệu trong tài liệu. Thứ nhất, tập kiểm tra chỉ được dùng một lần để báo cáo; mọi lựa chọn ngưỡng quyết định và chọn checkpoint đều thực hiện trên tập kiểm định. Thứ hai, khoảng tin cậy 95% được ước lượng bằng

bootstrap [12] với đơn vị lấy mẫu là nghiên cứu; so sánh giữa hai hệ thống dùng bootstrap ghép cặp trên cùng một tập nghiên cứu, 2.000 lần lấy mẫu lại. Thứ ba, một chênh lệch được coi là có ý nghĩa thống kê khi khoảng tin cậy không chứa 0; khi một cận của khoảng nằm cách 0 dưới 0,0005 thì kết quả được coi là chưa thiết lập được theo cả hai chiều, vì trong thực nghiệm dấu của cận đó thay đổi theo nhiễu Monte Carlo khi đổi luồng lấy mẫu. Thứ tư, mọi số liệu Giai đoạn 1 được tính lại từ tệp dự đoán đã lưu bằng mã nguồn nhánh chính và trùng khớp đến bốn chữ số thập phân với kết quả ghi nhận ban đầu. Thứ năm, đề tài không có bộ chấm lâm sàng đã được kiểm chứng (CheXbert, RadGraph); các mục này được ghi là không có chứ không ghi bằng 0, và các độ đo từ vựng không được trình bày như độ chính xác lâm sàng.

CHƯƠNG 2. GIAI ĐOẠN 1: PHÂN LOẠI BẤT THƯỜNG TRÊN 14 NHÃN

2.1. Kiến trúc được đánh giá

Giai đoạn 1 nhận một nghiên cứu gồm một ảnh chính và tối đa một ảnh phụ. Hai bộ mã hóa ảnh chuyên ngành y tế là BioViL-T [6] (nền ResNet-50, ảnh 448 điểm ảnh, lưới 14 nhân 14 gồm 196 token) và PubMedCLIP [7] (ViT-B/32, ảnh 224 điểm ảnh, một token toàn cục và 49 token vùng) được giữ nguyên thang đo gốc; đầu ra của chúng được hợp nhất góc nhìn theo từng bộ mã hóa, chiếu về cùng chiều 1.408 và nối lại thành chuỗi 246 token. Mô-đun phân loại chú ý chéo đa đầu (MHCAC) dự đoán cho mỗi nhãn một phân bố ba lớp dương tính, âm tính, không chắc chắn, có điều kiện là báo cáo nhắc tới bệnh lý đó; song song, một đầu cổng nhắc tới dự đoán xác suất báo cáo có nhắc tới bệnh lý. Khi huấn luyện, một nhánh giáo viên đọc thêm văn bản báo cáo và chưng cất phân bố của nó sang nhánh học viên chỉ dùng ảnh; khi suy luận chỉ nhánh học viên được dùng. Phần Q-Former của BLIP-2 [8] vẫn hiện diện nhưng các mục tiêu căn chỉnh ảnh văn bản (ITC, ITM, LM) được tắt vì lý do trình bày ở Mục 2.6.

2.2. Độ đo đánh giá

Mỗi nhãn được đánh giá như một bài toán nhị phân dương tính so với không dương tính. Các độ đo không phụ thuộc ngưỡng gồm diện tích dưới đường cong ROC (AUROC) và diện tích dưới đường cong precision recall (AUPRC). Các độ đo phụ thuộc ngưỡng gồm precision, recall (độ nhạy), F1 và specificity (độ đặc hiệu), tính tại ngưỡng đã hiệu chuẩn trên tập kiểm định. Trung bình macro lấy trung bình theo nhãn với trọng số bằng nhau; trung bình micro gộp mọi cặp nghiên cứu và nhãn thành một bảng xếp hạng duy nhất. Hai nhãn tổng hợp No Finding và Support Devices luôn được báo cáo riêng theo từng nhãn nhưng không tham gia các trung bình macro phụ thuộc ngưỡng. AUROC macro là độ đo chính của đề tài vì nó không bị ảnh hưởng bởi lựa chọn ngưỡng.

2.3. Hai cách diễn giải ma trận nhãn

Vì 79,5% ô nhãn của tập huấn luyện để trống, cùng một tệp dự đoán có thể được chấm theo hai cách cho kết quả rất khác nhau, và việc không nêu rõ cách chấm là nguồn gốc phổ biến của các so sánh không hợp lệ. Cách thứ nhất, phân cực có che (masked polarity), bỏ qua ô trống và chỉ hỏi phân cực của bệnh lý khi báo cáo đã nhắc tới nó. Cách thứ hai, hiện diện theo nghiên cứu (study presence), coi ô trống, âm tính và không

chắc chắn đều là không hiện diện, tức trả lời câu hỏi lâm sàng nghiên cứu này có bệnh lý hay không. Với cách thứ hai, điểm dự đoán có thể là xác suất dương tính có điều kiện (q) hoặc điểm hiện diện biên, bằng tích của xác suất được nhắc tới với xác suất dương tính có điều kiện; điểm biên đúng với câu hỏi được đặt ra vì phân bố q chỉ có nghĩa khi bệnh lý đã được nhắc tới.

Bảng 2.1. *Cùng một mô hình chấm theo ba cách, kèm các bộ dự đoán tầm thường (tập kiểm tra, 3.269 nghiên cứu)*

Cách chấm	AUROC macro	AUROC micro	F1 macro	Precision	Recall	Specificity
Phân cực có che, điểm q	0,7985	0,8849	0,8864	0,8684	0,9058	0,4673
Hiện diện, điểm q	0,7027	0,6578	0,3279	0,2660	0,5040	0,7679
Hiện diện, điểm biên (chính)	0,7643	0,8166	0,3542	0,2931	0,5373	0,8020
Baseline luôn dương tính, phân cực có che	không áp dụng	không áp dụng	0,8397	không áp dụng	1,0000	không áp dụng
Baseline lớp đa số, phân cực có che	không áp dụng	không áp dụng	0,8200	không áp dụng	0,9167	không áp dụng
Baseline luôn dương tính, hiện diện	không áp dụng	không áp dụng	0,2280	không áp dụng	1,0000	không áp dụng
Baseline lớp đa số, hiện diện	không áp dụng	không áp dụng	0,0000	không áp dụng	0,0000	không áp dụng

Mỗi cách chấm dùng ngưỡng hiệu chuẩn riêng trên tập kiểm định theo đúng cách chấm đó. Bộ dự đoán tầm thường không có điểm liên tục nên không có AUROC.

Bảng trên cho thấy lý do đề tài chỉ báo cáo F1 theo cách hiện diện. Theo cách phân cực có che, mô hình đạt F1 0,8864, nhưng bộ dự đoán luôn trả lời dương tính đã đạt 0,8397, nên mô hình chỉ hơn một hằng số 0,0468. Nguyên nhân là việc che ô trống đảo ngược tỉ lệ lớp: trong các ô được nhắc tới, dương tính chiếm đa số ở phần lớn các nhãn. Theo cách hiện diện, cả hai bộ dự đoán tầm thường về F1 bằng 0, và F1 0,3542 của mô hình là phần kỹ năng thực. Do đó mọi con số F1 khoảng 0,8 đến 0,9 trên MIMIC-CXR cần được đọc cùng cách chấm và cùng baseline tầm thường của chính cách chấm đó.

2.4. Hiệu chuẩn ngưỡng quyết định

Ngưỡng của từng nhãn được chọn trên tập kiểm định để tối đa F1, rồi áp dụng nguyên vẹn lên tập kiểm tra. Đề tài dùng quy tắc bình nguyên: thay vì lấy ngưỡng tại đỉnh F1, ngưỡng được đặt tại trung vị của mọi ngưỡng đạt ít nhất 95% giá trị đỉnh, vì đỉnh trên 1.808 nghiên cứu phụ thuộc vào vài nghiên cứu ngẫu nhiên nằm quanh nó còn vùng gần tối ưu thì chuyển giao tốt hơn. Nhãn có ít nhất 5 ca dương tính trên tập kiểm định mới được hiệu chuẩn; nhãn ít hơn giữ ngưỡng 0,5. Tác động của hai lựa chọn này được đo ở Mục 2.6.

2.5. Kết quả chính

Bảng 2.2. *Kết quả phân loại Giai đoạn 1 trên tập kiểm tra (hiện diện, điểm biên, 3.269 nghiên cứu)*

Độ đo	Giá trị	Khoảng tin cậy 95%
AUROC macro	0,7643	[0,7545; 0,7740]
AUROC micro	0,8166	không tính
AUPRC macro	0,3203	[0,3108; 0,3362]
F1 macro (dương tính)	0,3542	[0,3418; 0,3647]
Precision macro	0,2931	[0,2816; 0,3038]
Recall macro	0,5373	[0,5184; 0,5555]
Specificity macro	0,8020	không tính

Khoảng tin cậy bootstrap theo nghiên cứu, 1.000 lần lấy mẫu. Kết quả trùng khớp đến bốn chữ số với lần đánh giá ban đầu của cùng checkpoint.

Bảng 2.3. *Kết quả theo từng nhãn trên tập kiểm tra*

Nhãn	Số ca dương	Tỉ lệ	AUROC [KTC 95%]	AUPRC	Precision	Recall	F1	Specificity
Không có bất thường (No Finding)	568	17,4%	0,8081 [0,7891; 0,8274]	0,5342	0,5235	0,4912	0,5068	0,9060
Trung thất tim to (Enlarged Cardiomediastinum)	151	4,6%	0,6321 [0,5895; 0,6741]	0,0757	0,0862	0,2450	0,1276	0,8743
Tim to (Cardiomegaly)	866	26,5%	0,7694 [0,7517; 0,7874]	0,5101	0,3971	0,8487	0,5410	0,5356
Mờ phổi (Lung Opacity)	1.038	31,8%	0,7099 [0,6916; 0,7271]	0,5048	0,4510	0,7042	0,5498	0,6011
Tổn thương phổi (Lung Lesion)	123	3,8%	0,7655 [0,7239; 0,8015]	0,1216	0,1106	0,5366	0,1833	0,8312
Phù phổi (Edema)	683	20,9%	0,8353 [0,8197; 0,8505]	0,5764	0,5153	0,6179	0,5619	0,8465
Đông đặc (Consolidation)	220	6,7%	0,7483 [0,7174; 0,7782]	0,1918	0,2618	0,2273	0,2433	0,9538
Viêm phổi (Pneumonia)	335	10,2%	0,7046 [0,6744; 0,7346]	0,2266	0,2981	0,2866	0,2922	0,9230
Xẹp phổi (Atelectasis)	731	22,4%	0,7379 [0,7197; 0,7557]	0,4105	0,3595	0,7196	0,4795	0,6308
Tràn khí màng phổi (Pneumothorax)	112	3,4%	0,8585 [0,8257; 0,8916]	0,2711	0,2713	0,4554	0,3400	0,9566
Tràn dịch màng phổi (Pleural Effusion)	1.074	32,9%	0,8760 [0,8635; 0,8879]	0,7823	0,6378	0,8101	0,7137	0,7749
Bất thường màng phổi khác (Pleural Other)	63	1,9%	0,8667 [0,8345; 0,8997]	0,1029	0,0674	0,7937	0,1242	0,7842
Gãy xương (Fracture)	89	2,7%	0,6670 [0,6058; 0,7223]	0,0697	0,0606	0,2022	0,0933	0,9123
Thiết bị hỗ trợ (Support Devices)	1.125	34,4%	0,8838 [0,8708; 0,8956]	0,7745	0,6829	0,8364	0,7519	0,7962

KTC: khoảng tin cậy, bootstrap theo nghiên cứu 1.000 lần. Tỉ lệ là tỉ lệ dương tính theo cách hiện diện trên tập kiểm tra.

AUROC macro đạt 0,7643. Nhãn phân biệt tốt nhất là Thiết bị hỗ trợ (Support Devices) (0,8838) và Tràn dịch màng phổi (Pleural Effusion) (0,8760); nhãn khó nhất là Trung thất tim to (Enlarged Cardiomediastinum) (0,6321) và Gãy xương (Fracture)

(0,6670). Các nhãn hiếm có khoảng tin cậy rộng và F1 dao động mạnh theo ngưỡng, vì vậy khi so sánh theo nhãn nên ưu tiên AUROC kèm tỉ lệ dương tính thay vì F1.

2.6. Nghiên cứu cắt bỏ

2.6.1. Các thành phần được đo lại có đối chứng

Mỗi dòng trong hai bảng dưới đây so sánh hai lần chấm trên cùng 3.269 nghiên cứu kiểm tra, mỗi bên dùng ngưỡng hiệu chuẩn trên tập kiểm định của chính nó, và chỉ khác nhau đúng một thành phần. Cấu hình của các lần chạy được đối chiếu từng khóa từ nhật ký huấn luyện trước khi so sánh. Chênh lệch được tính là hệ thống sau trừ hệ thống trước; giá trị in đậm là khoảng tin cậy không chứa 0 và không nằm sát biên. Bảng thứ nhất báo cáo các độ đo không phụ thuộc ngưỡng, phản ánh khả năng phân biệt của mô hình; bảng thứ hai báo cáo các độ đo tại ngưỡng, phản ánh điểm vận hành.

Bảng 2.4. *Chênh lệch khả năng phân biệt (tập kiểm tra, bootstrap ghép cặp 2.000 lần)*

Thành phần thay đổi	AUROC macro	AUROC micro	AUPRC macro
Mở khóa phần trên bộ mã hóa (đóng băng sang mở khóa nông)	**+0,0201 [+0,0139; +0,0266]**	-0,0017 [-0,0047; +0,0014]	**+0,0199 [+0,0127; +0,0279]**
Mở khóa sâu hơn (nông sang sâu)	+0,0049 [-0,0002; +0,0098]	+0,0021 [+0,0001; +0,0040]	+0,0066 [-0,0002; +0,0134]
Hàm mất mát phân cấp, cấu hình nông	+0,0047 [-0,0002; +0,0096]	**+0,0273 [+0,0247; +0,0299]**	+0,0059 [-0,0010; +0,0130]
Hàm mất mát phân cấp, cấu hình sâu	+0,0002 [-0,0045; +0,0046]	**+0,0247 [+0,0222; +0,0273]**	+0,0016 [-0,0039; +0,0081]
Dùng cổng nhắc tới khi chấm (điểm q sang điểm biên)	**+0,0616 [+0,0527; +0,0706]**	**+0,1588 [+0,1543; +0,1638]**	**+0,0351 [+0,0283; +0,0437]**
Chọn ngưỡng theo bình nguyên thay vì đỉnh	không đổi (cùng điểm số)	không đổi (cùng điểm số)	không đổi (cùng điểm số)
Hạ số ca dương tối thiểu để hiệu chuẩn từ 20 xuống 5	không đổi (cùng điểm số)	không đổi (cùng điểm số)	không đổi (cùng điểm số)

Bảng 2.5. *Chênh lệch tại điểm vận hành (tập kiểm tra, bootstrap ghép cặp 2.000 lần)*

Thành phần thay đổi	F1 macro	Precision	Recall	Specificity
Mở khóa phần trên bộ mã hóa (đóng băng sang mở khóa nông)	**+0,0144 [+0,0053; +0,0231]**	**+0,0155 [+0,0073; +0,0233]**	**+0,0366 [+0,0204; +0,0522]**	**+0,0119 [+0,0085; +0,0155]**
Mở khóa sâu hơn (nông sang sâu)	-0,0023 [-0,0124; +0,0078]	+0,0077 [-0,0025; +0,0199]	**-0,0937 [-0,1099; -0,0770]**	**+0,0375 [+0,0343; +0,0408]**
Hàm mất mát phân cấp, cấu hình nông	-0,0006 [-0,0100; +0,0093]	**+0,0145 [+0,0036; +0,0265]**	**-0,0759 [-0,0898; -0,0616]**	**+0,0305 [+0,0277; +0,0336]**
Hàm mất mát phân cấp, cấu hình sâu	+0,0099 [-0,0013; +0,0203]	+0,0074 [-0,0049; +0,0183]	**+0,0345 [+0,0181; +0,0498]**	**-0,0101 [-0,0129; -0,0073]**
Dùng cổng nhắc tới khi chấm (điểm q sang điểm biên)	**+0,0262 [+0,0185; +0,0334]**	**+0,0270 [+0,0194; +0,0343]**	**+0,0333 [+0,0167; +0,0495]**	**+0,0341 [+0,0295; +0,0384]**
Chọn ngưỡng theo bình nguyên thay vì đỉnh	+0,0027 [-0,0013; +0,0071]	**-0,0126 [-0,0160; -0,0090]**	**+0,0434 [+0,0371; +0,0503]**	**-0,0331 [-0,0352; -0,0310]**
Hạ số ca dương tối thiểu để hiệu chuẩn từ 20 xuống 5	**+0,0181 [+0,0140; +0,0227]**	**-0,0458 [-0,0491; -0,0423]**	**+0,0830 [+0,0720; +0,0941]**	**-0,0253 [-0,0268; -0,0237]**

Dòng mở khóa bộ mã hóa đồng thời đổi hệ số kappa của trọng số lớp về 1, nên hai yếu tố này không tách được trong phép so sánh này.

Trong các thay đổi về huấn luyện, việc mở khóa phần trên của hai bộ mã hóa là thay đổi duy nhất cải thiện khả năng phân biệt: AUROC macro thay đổi +0,0201 và kết quả có ý nghĩa thống kê. Lập luận gián tiếp để quy tác động cho việc mở khóa thay vì hệ số kappa là kappa chỉ dịch chuyển điểm vận hành, vốn đã được ngưỡng hiệu chuẩn hấp thụ, còn AUROC là đại lượng kappa không thể thay đổi về nguyên tắc; tuy vậy đây là suy luận chứ chưa phải phép cắt bỏ riêng. Mở khóa sâu hơn cho AUROC macro +0,0049 (nằm sát biên 0 nên chưa thiết lập được), trong khi các thay đổi lớn nằm ở recall và specificity, là dấu hiệu điểm vận hành dịch chuyển chứ không phải mô hình tốt hơn.

Dùng cổng nhắc tới khi chấm, tức thay xác suất dương tính có điều kiện bằng điểm hiện diện biên, thay đổi AUROC macro +0,0616 (có ý nghĩa thống kê). Đây là bằng chứng rằng đầu cổng nhắc tới, vốn là thành phần duy nhất học từ 79,5% ô nhãn để trống, mang thông tin mà nhánh phân loại ba lớp không có.

Hàm mất mát phân cấp, huấn luyện chung xác suất nhắc tới và phân bố phân cực thành một hàm hợp lý duy nhất, cho AUROC macro +0,0047 (nằm sát biên 0 nên chưa thiết lập được) nhưng AUROC micro +0,0273 (có ý nghĩa thống kê), và kết quả cùng dạng lặp lại trên cấu hình sâu. AUROC micro gộp mọi nhãn vào một bảng xếp hạng nên nhạy với việc điểm số có cùng ý nghĩa giữa các nhãn hay không, còn AUROC theo từng nhãn không đổi dưới mọi phép co giãn đơn điệu riêng của từng nhãn. Vì vậy hàm mất mát phân cấp cải thiện tính hiệu chuẩn giữa các nhãn chứ không cải thiện khả năng phân biệt từng nhãn; trong một quy trình đã hiệu chuẩn ngưỡng riêng cho từng nhãn, tính chất này không mở rộng tập điểm vận hành đạt được.

Hai lựa chọn về ngưỡng tách được tác động của nhau. Chọn ngưỡng theo bình nguyên thay vì đỉnh thay đổi F1 macro +0,0027 (không có ý nghĩa thống kê), còn hạ số ca dương tối thiểu để hiệu chuẩn từ 20 xuống 5 thay đổi F1 macro +0,0181 (có ý nghĩa thống kê). Phần cải thiện F1 của quy trình hiệu chuẩn vì vậy đến từ việc cho phép hiệu chuẩn các nhãn hiếm: với ngưỡng tối thiểu 20 ca, Bất thường màng phổi khác (Pleural Other) và Gãy xương (Fracture) giữ ngưỡng mặc định 0,5 và không được dự đoán dương tính ở bất kỳ nghiên cứu kiểm tra nào; khi hạ xuống 5 ca, Bất thường màng phổi khác (Pleural Other) nhận ngưỡng 0,158 với recall 0,7937 và Gãy xương (Fracture) nhận ngưỡng 0,235 với recall 0,2022. Cả hai lựa chọn đều đổi precision lấy recall (precision

-0,0458, recall +0,0830 với lựa chọn thứ hai), và cả hai giữ nguyên AUROC vì chỉ ngưỡng thay đổi còn điểm số của mô hình thì không.

2.6.2. Các thành phần chỉ còn kết quả ghi nhận

Ba thí nghiệm cắt bỏ khác được thực hiện trong quá trình phát triển nhưng không thể chấm lại, vì checkpoint của chúng bị mất khi máy huấn luyện được cài đặt lại hoặc tệp dự đoán tương ứng không được lưu. Kết quả dưới đây là số liệu ghi nhận tại thời điểm thí nghiệm, được trình bày để đầy đủ và không có cùng mức bảo đảm tái lập như Mục 2.6.1. Riêng thí nghiệm hàm mất mát giải thích được chấm theo cách phân cực có che với bộ mã hóa đóng băng, nên không so trực tiếp được với các bảng khác trong chương này.

Bảng 2.6. *Hàm mất mát giải thích dựa trên Grad-CAM [23], 5 epoch, bật so với tắt (số liệu ghi nhận)*

Độ đo	Bật (0,05 và 0,25)	Tắt
F1 macro (phân cực có che)	0,8757	0,8767
AUROC macro	0,7850	0,7879
Specificity macro	0,3840	0,4127
Thời gian huấn luyện	5 giờ 06 phút 44 giây	4 giờ 25 phút 27 giây

Mọi khoảng tin cậy 95% chồng lấn; mọi chênh lệch nghiêng về phía tắt; chi phí huấn luyện tăng 15,5%. Độ chính xác bản đồ nổi bật ở cả hai nhánh đều xấp xỉ mức ngẫu nhiên bằng tỉ lệ diện tích mặt nạ.

Bảng 2.7. *Cổng kiểm tra học tương phản ảnh văn bản của Q-Former trên tập kiểm định (số liệu ghi nhận)*

Lần đo	Nhiệt độ	Hạng trung bình ảnh sang văn bản	Hạng trung bình văn bản sang ảnh	Chênh lệch so với ngẫu nhiên (nats)
Chưa huấn luyện	0,07 cố định	130,68	130,30	-0,0833
525 bước cập nhật	0,00796 học được	127,43	127,65	-1,1168
500 bước cập nhật	0,07 cố định	128,38	127,45	-0,0025
Khoảng 525 bước, lần đo thứ tư	0,00944 học được	127,49	127,76	-0,0118

256 cặp hợp lệ, hạng kỳ vọng khi ngẫu nhiên là 127,5; ngưỡng đạt yêu cầu là chênh lệch tối thiểu +0,10 nats. Cả bốn lần đều ở mức ngẫu nhiên.

Bảng 2.8. *Huấn luyện thêm 5 epoch (epoch 14 so với epoch 9, tập kiểm tra, số liệu ghi nhận)*

Độ đo	Chênh lệch	Kết luận
AUROC macro	-0,0005 [-0,0043; +0,0031]	Không có ý nghĩa
F1 macro	-0,0067	Khoảng tin cậy chứa 0
Precision macro	+0,0015	Khoảng tin cậy chứa 0
Recall macro	-0,0826	Có ý nghĩa, do ngưỡng dịch chuyển
Specificity macro	+0,0244	Có ý nghĩa, do ngưỡng dịch chuyển

AUROC cải thiện ở 6 trên 14 nhãn. Trên tập kiểm định, AUROC macro tăng +0,0082 [+0,0015; +0,0148] nhưng không lặp lại trên tập kiểm tra.

Kết quả Q-Former ở mức ngẫu nhiên phù hợp với giải thích từ tài liệu: BLIP-2 huấn luyện học tương phản với lô 1.680 đến 2.320 mẫu [8], trong khi cấu hình khả thi trên một GPU 16 GB của đề tài chỉ có lô 8. Mã nguồn tham chiếu của bài báo gốc [4] cũng không huấn luyện các mục tiêu này. Vì vậy các trọng số ITC, ITM, LM được đặt bằng 0 trong mô hình chính, và 32 token mềm của Q-Former là một phép đọc cố định, chưa được thích nghi, của đặc trưng ảnh.

2.7. So sánh với công trình liên quan

Bảng 2.9. *AUROC theo nhãn: CheXclusion [20] và đề tài*

Nhãn	CheXclusion	Đề tài [KTC 95%]	Chênh lệch
Không có bất thường (No Finding)	0,868	0,8081 [0,7891; 0,8274]	-0,0599
Trung thất tim to (Enlarged Cardiomediastinum)	0,757	0,6321 [0,5895; 0,6741]	-0,1249
Tim to (Cardiomegaly)	0,828	0,7694 [0,7517; 0,7874]	-0,0586
Mờ phổi (Lung Opacity)	0,782	0,7099 [0,6916; 0,7271]	-0,0721
Tổn thương phổi (Lung Lesion)	0,772	0,7655 [0,7239; 0,8015]	-0,0065
Phù phổi (Edema)	0,904	0,8353 [0,8197; 0,8505]	-0,0687
Đông đặc (Consolidation)	0,844	0,7483 [0,7174; 0,7782]	-0,0957
Viêm phổi (Pneumonia)	0,748	0,7046 [0,6744; 0,7346]	-0,0434
Xẹp phổi (Atelectasis)	0,837	0,7379 [0,7197; 0,7557]	-0,0991
Tràn khí màng phổi (Pneumothorax)	0,903	0,8585 [0,8257; 0,8916]	-0,0445
Tràn dịch màng phổi (Pleural Effusion)	0,933	0,8760 [0,8635; 0,8879]	-0,0570
Bất thường màng phổi khác (Pleural Other)	0,848	0,8667 [0,8345; 0,8997]	+0,0187
Gãy xương (Fracture)	0,718	0,6670 [0,6058; 0,7223]	-0,0510
Thiết bị hỗ trợ (Support Devices)	0,927	0,8838 [0,8708; 0,8956]	-0,0432
Trung bình 14 nhãn	0,834	0,7759	-0,0581

Số của CheXclusion lấy từ Bảng 2 của công trình, cột MIMIC-CXR, trung bình 5 lần chạy. Trung bình 14 nhãn của đề tài ở đây gồm cả hai nhãn tổng hợp để khớp cách tính của CheXclusion, nên khác AUROC macro chính.

Bảng 2.10. *Khác biệt giao thức giữa CheXclusion và đề tài*

Khía cạnh	CheXclusion	Đề tài
Dữ liệu	MIMIC-CXR, 371.858 ảnh	MIMIC-CXR-JPG 2.1.0
Chính sách nhãn	Mọi nhãn không dương tính là âm tính	Hiện diện theo nghiên cứu, tương đương
Đơn vị đánh giá	Ảnh	Nghiên cứu (ảnh chính và tối đa một ảnh phụ)
Phân chia	Ngẫu nhiên 80, 10, 10 theo bệnh nhân	Phân chia chính thức
Mô hình	DenseNet-121 khởi tạo ImageNet	BioViL-T và PubMedCLIP, hợp nhất góc nhìn, MHCAC
Chọn ngưỡng	Tối đa F1 trên tập kiểm định	Bình nguyên F1 trên tập kiểm định
Số lần chạy	5 hạt giống, báo cáo trung bình	1 lần chạy

Đề tài có AUROC thấp hơn CheXclusion ở 13 trên 14 nhãn, chênh lệch trung bình -0,058. Chính sách nhãn của hai bên tương đương, nhưng ba khác biệt giao thức khiến

hai bộ số không phải phép so sánh ngang hàng: đơn vị ảnh so với nghiên cứu, phân chia ngẫu nhiên so với phân chia chính thức, và trung bình 5 lần chạy so với một lần chạy. Kết luận trung thực là trên cùng câu hỏi hiện diện bệnh lý, bộ phân loại của đề tài chưa đạt mức của một đường cơ sở CNN chuyên phân loại; đóng góp của Giai đoạn 1 nằm ở việc cung cấp đầu ra có cấu trúc và cổng nhắc tới cho Giai đoạn 2, không phải ở độ chính xác phân loại vượt trội.

CHƯƠNG 3. GIAI ĐOẠN 2: SINH BÁO CÁO

3.1. Các hệ thống được đánh giá

Giai đoạn 2 dùng mô hình ngôn ngữ thị giác MedGemma 1.5 4B [9] tinh chỉnh bằng QLoRA [10, 11] chỉ trên tháp ngôn ngữ, sinh phần FINDINGS của báo cáo. Ba hệ thống được so sánh trên cùng tập kiểm tra. Hệ thống không tinh chỉnh là MedGemma nguyên bản, dùng làm mốc đối chứng. Hệ thống A tinh chỉnh MedGemma chỉ với ảnh gốc qua tháp ảnh của chính nó, không dùng bất kỳ đầu ra nào của Giai đoạn 1. Hệ thống C là kiến trúc thiết kế ban đầu của đề tài: MedGemma giữ tháp ảnh của mình, đồng thời nhận thêm 32 token mềm từ Q-Former được chiếu vào không gian nhúng qua một lớp tuyến tính huấn luyện được, và nhận các gợi ý dương tính, âm tính, không chắc chắn từ Giai đoạn 1 dưới dạng văn bản. Hệ thống C được suy luận với đúng quy tắc tạo gợi ý mà nó đã được huấn luyện.

3.2. Cấu hình giải mã

Cả ba hệ thống dùng giải mã tham lam, tối đa 160 token mới, không dùng hình phạt lặp và không chặn n-gram lặp. Điều kiện dừng gồm cả hai mã kết thúc mà cấu hình sinh của MedGemma khai báo: mã kết thúc chuỗi (1) và mã kết thúc lượt hội thoại end_of_turn (106). Chi tiết này quyết định kết quả và được phân tích ở Mục 3.5: trước khi sửa, mã nguồn chỉ dừng ở mã 1, trong khi báo cáo đích dùng khi huấn luyện kết thúc bằng mã 106.

3.3. Độ đo và giao thức chấm điểm

Các độ đo từ vựng gồm BLEU-1 đến BLEU-4 [13], METEOR [14], ROUGE-L [15] và CIDEr [16], tính bằng bộ công cụ coco-caption [18] (thư viện pycocoevalcap) sau khi tách từ bằng PTBTokenizer; đây là giao thức mà R2Gen [5] và các công trình kế tiếp sử dụng. METEOR là phiên bản 1.5 chạy trên Java. Độ tương đồng ngữ nghĩa được đo bằng BERTScore [17] với mô hình RoBERTa-large [19], mặc định của thư viện bert_score cho tiếng Anh, ở cả dạng thô và dạng đã co giãn theo đường cơ sở; hai dạng này khác nhau rất xa về giá trị tuyệt đối nên luôn được ghi rõ. Khoảng tin cậy của METEOR, ROUGE-L, CIDEr và BERTScore được tính trên trung bình điểm từng nghiên cứu; của BLEU-4 được tính bằng cách tính lại BLEU cấp kho văn bản trên mỗi mẫu bootstrap, vì BLEU không phải trung bình điểm từng câu.

Bộ chấm nội bộ của mã nguồn tính METEOR bằng thư viện nltk, BLEU bằng cài đặt riêng có làm trơn cộng một, và BERTScore bằng DistilBERT dạng thô. Các lựa chọn này hợp lệ cho so sánh nội bộ nhưng cho giá trị khác hẳn giao thức chuẩn, nên không được dùng để so với công trình khác. Bảng dưới đây đặt hai giao thức cạnh nhau trên cùng các báo cáo sinh ra, để minh họa mức chênh lệch.

Bảng 3.1. *Cùng báo cáo sinh ra, chấm bằng bộ chấm nội bộ và bằng giao thức chuẩn (tập kiểm tra)*

Hệ thống	METEOR nltk	METEOR 1.5	BLEU-4 nội bộ	BLEU-4 coco	BERTScore DistilBERT	BERTScore RoBERTa-L
MedGemma không tinh chỉnh	0,2613	0,1356	0,0715	0,0556	0,8129	0,8525
Hệ thống A (ảnh gốc, tinh chỉnh)	0,2143	0,0964	0,0583	0,0452	0,7955	0,8543
Hệ thống C (kết hợp, tinh chỉnh)	0,1937	0,0796	0,0395	0,0277	0,7650	0,8422

3.4. Kết quả trên tập kiểm tra

Bảng 3.2. *Kết quả sinh báo cáo trên tập kiểm tra (2.772 nghiên cứu, giao thức chuẩn)*

Hệ thống	BLEU-1	BLEU-2	BLEU-3	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTS thô	BERTS co giãn
MedGemma không tinh chỉnh	0,2770	0,1539	0,0913	0,0556	0,1356	0,1995	0,0791	0,8525	0,1260
Hệ thống A (ảnh gốc, tinh chỉnh)	0,1638	0,0992	0,0653	0,0452	0,0964	0,1912	0,1439	0,8543	0,1370
Hệ thống C (kết hợp, tinh chỉnh)	0,0920	0,0572	0,0388	0,0277	0,0796	0,1728	0,1950	0,8422	0,0652

BERTS: BERTScore F1 với RoBERTa-large. Độ đo lâm sàng (CheXbert, RadGraph) không có trong đề tài và không được thay bằng giá trị 0.

Bảng 3.3. *Độ dài và hiện tượng lặp của báo cáo sinh ra trên tập kiểm tra*

Hệ thống	Trung vị số từ sinh ra	Trung vị số từ tham chiếu	Báo cáo rỗng	Có 5-gram lặp từ 3 lần
MedGemma không tinh chỉnh	63	56	0,0%	12,0%
Hệ thống A (ảnh gốc, tinh chỉnh)	31	56	0,0%	0,1%
Hệ thống C (kết hợp, tinh chỉnh)	6	56	0,0%	0,1%

Bảng 3.4. *Chênh lệch ghép cặp trên tập kiểm tra (bootstrap 2.000 lần; BLEU-4 500 lần)*

So sánh	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTScore thô
Hệ thống A trừ không tinh chỉnh	**-0,0103 [-0,0138; -0,0068]**	**-0,0274 [-0,0313; -0,0233]**	**-0,0084 [-0,0146; -0,0023]**	**+0,0647 [+0,0376; +0,0957]**	+0,0019 [+0,0001; +0,0037]
Hệ thống C trừ không tinh chỉnh	**-0,0279 [-0,0308; -0,0246]**	**-0,0374 [-0,0424; -0,0323]**	**-0,0267 [-0,0344; -0,0186]**	**+0,1159 [+0,0801; +0,1555]**	**-0,0103 [-0,0125; -0,0079]**

So sánh	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTScore thô
Hệ thống C trừ hệ thống A	**-0,0176 [-0,0200; -0,0148]**	**-0,0101 [-0,0135; -0,0064]**	**-0,0184 [-0,0243; -0,0122]**	**+0,0512 [+0,0260; +0,0795]**	**-0,0121 [-0,0139; -0,0103]**

Giá trị in đậm là khoảng tin cậy không chứa 0 và không nằm sát biên.

So với MedGemma không tinh chỉnh, hệ thống A thay đổi CIDEr +0,0647 (có ý nghĩa thống kê), METEOR -0,0274 (có ý nghĩa thống kê) và BERTScore thô +0,0019 (nằm sát biên 0 nên chưa thiết lập được). Hệ thống C so với hệ thống A thay đổi CIDEr +0,0512 (có ý nghĩa thống kê) và BERTScore thô -0,0121 (có ý nghĩa thống kê). Trung vị độ dài báo cáo sinh ra của hệ thống A là 31 từ so với 56 từ của báo cáo tham chiếu. Báo cáo ngắn hơn đáng kể so với tham chiếu làm giảm BLEU qua hệ số phạt độ ngắn và giảm METEOR vốn thưởng cho độ phủ, nên độ ngắn là một hạn chế cần được đọc cùng các độ đo này.

3.4.1. Hiện tượng sụp về mẫu câu ngắn

Bảng 3.5. *Phân bố độ dài và mức độ lặp mẫu câu của báo cáo sinh ra trên tập kiểm tra (2.772 nghiên cứu)*

Hệ thống	Trung vị số từ	Tỉ lệ từ 10 từ trở xuống	Tỉ lệ từ 5 từ trở xuống	Số đầu ra khác nhau	Tỉ lệ đầu ra phổ biến nhất	Tỉ lệ 5 đầu ra phổ biến nhất
MedGemma không tinh chỉnh	63	0,0%	0,0%	2.684	0,3%	1,4%
Hệ thống A (ảnh gốc, tinh chỉnh)	31	26,9%	5,6%	1.783	5,6%	17,6%
Hệ thống C (kết hợp, tinh chỉnh)	6	50,9%	11,1%	1.220	11,1%	32,5%

Hai đầu ra được coi là giống nhau khi trùng khớp hoàn toàn về chuỗi ký tự. Nội dung văn bản không được trình bày vì là dữ liệu dẫn xuất từ MIMIC-CXR.

Trung vị độ dài của hệ thống C trên tập kiểm tra chỉ là 6 từ, trong khi báo cáo tham chiếu có trung vị 56 từ. Phân bố độ dài có dạng hai đỉnh: 50,9% báo cáo của hệ thống C có từ 10 từ trở xuống, và riêng đầu ra phổ biến nhất, một chuỗi 4 từ, chiếm 11,1% tổng số nghiên cứu; năm đầu ra phổ biến nhất chiếm 32,5%. Hệ thống A có cùng hiện tượng ở mức nhẹ hơn, với 26,9% báo cáo từ 10 từ trở xuống và đầu ra phổ biến nhất chiếm 5,6%. MedGemma không tinh chỉnh không sinh báo cáo nào ngắn như vậy. Có ba kiểm tra cho thấy đây là hành vi của mô hình chứ không phải lỗi của quy trình đánh giá. Thứ nhất, độ ngắn không đi theo độ dài của báo cáo tham chiếu: trung vị độ dài tham chiếu của nhóm báo cáo sinh ngắn là 56 từ và của nhóm còn lại là 56 từ, trong khi chỉ 6,7% báo cáo tham chiếu có từ 15 từ trở xuống. Thứ hai, 679 nghiên cứu cho đầu ra ngắn ở cả hai hệ thống A và C, tức là cùng một nhóm ảnh kéo cả hai mô hình tinh chỉnh về câu mẫu. Thứ ba, tệp tóm tắt quá trình sinh xác nhận quy tắc gợi ý, danh sách mã dừng và số nghiên cứu đúng

như cấu hình. Trên 100 nghiên cứu kiểm định với cùng quy tắc gợi ý, trung vị độ dài là 21 từ và 30,0% báo cáo có từ 10 từ trở xuống, nên mức sụp trên tập kiểm tra nặng hơn trên tập kiểm định. Hiện tượng này giải thích vì sao hệ thống C có CIDEr cao nhất nhưng BLEU, METEOR, ROUGE-L và BERTScore thấp nhất: các độ đo dựa trên độ phủ và độ dài phạt nặng báo cáo ngắn, còn CIDEr không phản ánh cùng chiều. Vì vậy CIDEr không được dùng riêng lẻ để kết luận hệ thống C tốt hơn.

3.5. Lỗi điều kiện dừng sinh

Trong quá trình phát triển, mã nguồn ghi đè danh sách mã dừng của mô hình bằng mã kết thúc của bộ tách từ, làm mất mã end_of_turn mà báo cáo đích dùng để kết thúc. Thí nghiệm có đối chứng dưới đây dùng 25 nghiên cứu kiểm định được chọn theo hạt giống trước khi xem đầu ra, chạy bốn nhánh trong cùng một phiên nạp mô hình với thứ tự luân phiên; số token là số đếm chính xác chứ không phải ước lượng.

Bảng 3.6. *Số token sinh ra trước và sau khi sửa điều kiện dừng (25 nghiên cứu, số liệu ghi nhận)*

Nhánh	Tổng token	Chạm giới hạn 160	Có sinh end_of_turn	Token sau end_of_turn
Không gợi ý, mã dừng cũ	4.000	25 trên 25	25 trên 25	3.112
Không gợi ý, mã dừng đúng	888	0 trên 25	25 trên 25	0
Gợi ý chọn lọc, mã dừng cũ	4.000	25 trên 25	25 trên 25	3.096
Gợi ý chọn lọc, mã dừng đúng	904	0 trên 25	25 trên 25	0

Bảng 3.7. *Chất lượng báo cáo trước và sau khi sửa điều kiện dừng (25 nghiên cứu, giao thức chuẩn)*

Nhánh	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTS thô	Trung vị từ	Lặp 5-gram
Không gợi ý, mã dừng cũ	0,0494	0,1462	0,1992	0,0061	0,8408	102	64,0%
Không gợi ý, mã dừng đúng	0,0634	0,1176	0,2230	0,2586	0,8646	21	0,0%
Gợi ý chọn lọc, mã dừng cũ	0,0487	0,1557	0,2121	0,0061	0,8416	104	64,0%
Gợi ý chọn lọc, mã dừng đúng	0,0657	0,1200	0,2266	0,2502	0,8653	21	0,0%

Mô hình phát tín hiệu kết thúc ở mọi lần sinh, nhưng mã nguồn buộc nó viết tiếp: 3.112 trên 4.000 token, tức 78%, nằm sau mã end_of_turn. Sau khi sửa, không lần sinh nào chạm giới hạn độ dài và không còn token nào sau mã kết thúc. Lỗi này tác động đối xứng lên mọi hệ thống từng được so sánh, nên các kết luận tương đối trước đó nhiều khả năng vẫn đứng vững, nhưng mọi con số tuyệt đối của Giai đoạn 2 sinh trước khi sửa đều không dùng được. Toàn bộ kết quả kiểm tra trong chương này được sinh lại sau khi sửa.

3.6. Nghiên cứu cắt bỏ các kênh thông tin từ Giai đoạn 1

3.6.1. Quy tắc tạo gợi ý văn bản

Hệ thống C nhận đầu ra Giai đoạn 1 dưới dạng danh sách bệnh lý dương tính, âm tính, không chắc chắn. Thí nghiệm này giữ nguyên checkpoint hệ thống C, cùng 100 nghiên cứu kiểm định và cùng cấu hình giải mã đã sửa điều kiện dừng, chỉ đổi quy tắc chuyển xác suất thành gợi ý, bao gồm các quy tắc có precision cao hơn quy tắc gốc ở cùng mức recall.

Bảng 3.8. *Chênh lệch so với không dùng gợi ý (100 nghiên cứu kiểm định, giao thức chuẩn)*

Quy tắc tạo gợi ý	METEOR	ROUGE-L	CIDEr	BERTScore thô
Quy tắc gốc theo xác suất có điều kiện	+0,0000 [-0,0073; +0,0075]	+0,0008 [-0,0099; +0,0113]	-0,0177 [-0,0488; +0,0090]	-0,0026 [-0,0072; +0,0012]
Ngưỡng trên điểm biên	+0,0013 [-0,0039; +0,0067]	+0,0023 [-0,0055; +0,0124]	-0,0123 [-0,0445; +0,0162]	-0,0002 [-0,0030; +0,0025]
Chọn lọc, precision 0,70	+0,0022 [-0,0035; +0,0081]	+0,0056 [-0,0037; +0,0158]	-0,0114 [-0,0379; +0,0123]	+0,0010 [-0,0027; +0,0049]
Cân bằng, precision 0,50	+0,0012 [-0,0033; +0,0062]	+0,0030 [-0,0043; +0,0109]	-0,0045 [-0,0266; +0,0138]	+0,0001 [-0,0030; +0,0034]
Ưu tiên recall, precision 0,35	-0,0018 [-0,0093; +0,0054]	-0,0015 [-0,0119; +0,0095]	-0,0054 [-0,0377; +0,0276]	-0,0013 [-0,0047; +0,0022]

Không quy tắc nào cải thiện có ý nghĩa thống kê so với việc không đưa gợi ý, kể cả quy tắc ưu tiên recall vốn trội hơn quy tắc gốc đồng thời về precision và recall. Do đó việc gợi ý văn bản không giúp ích không bắt nguồn từ việc chọn sai điểm vận hành.

3.6.2. Token phát hiện học được và kiểm tra việc sử dụng kênh

Để kiểm tra giả thuyết rằng vấn đề nằm ở kênh truyền dạng văn bản chứ không ở thông tin, đề tài thử một kênh khác: 13 token học được, mỗi token mang danh tính một bệnh lý cùng các giá trị liên tục của cổng nhắc tới và phân bố phân cực. Bốn nhánh được huấn luyện trên cùng 10.000 nghiên cứu, cùng hạt giống và cùng cấu hình, rồi sinh trên cùng 300 nghiên cứu kiểm định: A không gợi ý, B gợi ý văn bản, C token chỉ mang phân cực, D token mang đầy đủ cổng nhắc tới và phân cực. Ba can thiệp khi suy luận trên nhánh D kiểm tra mô hình có thực sự đọc kênh này hay không; đây là can thiệp ngoài phân phối, chỉ dùng như phép thăm dò cơ chế.

Bảng 3.9. *Kênh gợi ý văn bản và token phát hiện (300 nghiên cứu kiểm định, giao thức chuẩn)*

So sánh	METEOR	ROUGE-L	CIDEr	BERTScore thô
B trừ A: gợi ý văn bản	-0,0006 [-0,0043; +0,0032]	+0,0002 [-0,0060; +0,0062]	+0,0133 [-0,0085; +0,0376]	-0,0013 [-0,0031; +0,0005]
C trừ A: token phân cực	-0,0025 [-0,0072; +0,0020]	-0,0034 [-0,0114; +0,0044]	-0,0110 [-0,0452; +0,0197]	-0,0020 [-0,0044; +0,0002]

So sánh	METEOR	ROUGE-L	CIDEr	BERTScore thô
D trừ A: token đầy đủ	-0,0030 [-0,0080; +0,0016]	-0,0067 [-0,0151; +0,0010]	-0,0062 [-0,0348; +0,0196]	**-0,0041 [-0,0066; -0,0017]**
D trừ B: token so với văn bản	-0,0024 [-0,0073; +0,0022]	-0,0069 [-0,0154; +0,0014]	-0,0195 [-0,0514; +0,0093]	-0,0027 [-0,0053; -0,0004]
D trừ C: đóng góp của cổng nhắc tới	-0,0005 [-0,0042; +0,0030]	-0,0033 [-0,0096; +0,0027]	+0,0048 [-0,0240; +0,0367]	-0,0020 [-0,0039; -0,0003]
Xóa giá trị token	+0,0007 [-0,0035; +0,0054]	+0,0008 [-0,0061; +0,0081]	+0,0360 [-0,0031; +0,0980]	+0,0011 [-0,0008; +0,0033]
Đảo token giữa các bệnh lý	+0,0016 [-0,0011; +0,0046]	+0,0040 [-0,0012; +0,0093]	+0,0133 [-0,0075; +0,0378]	+0,0009 [-0,0008; +0,0025]
Tráo token giữa các nghiên cứu	+0,0017 [-0,0019; +0,0056]	-0,0001 [-0,0067; +0,0064]	-0,0030 [-0,0335; +0,0277]	+0,0006 [-0,0014; +0,0027]

Ba dòng cuối là can thiệp khi suy luận trên checkpoint D, ngoài phân phối huấn luyện.

Kênh token học được, mang nhiều thông tin hơn gợi ý văn bản, không tốt hơn gợi ý văn bản cũng như không tốt hơn việc không dùng gợi ý; thêm cổng nhắc tới vào token cũng không tạo khác biệt. Ba phép can thiệp khi suy luận, gồm xóa hoàn toàn giá trị, gán giá trị cho sai bệnh lý và dùng dự đoán của bệnh nhân khác, đều không làm thay đổi đầu ra một cách có ý nghĩa. Mô hình sau huấn luyện không sử dụng kênh này.

3.6.3. Thay mô hình Giai đoạn 1

Bảng 3.10. *Giai đoạn 2 với Giai đoạn 1 dùng hàm mất mát phân cấp (300 nghiên cứu kiểm định)*

So sánh	METEOR	ROUGE-L	CIDEr	BERTScore thô
Không gợi ý: Giai đoạn 1 mới trừ cũ	+0,0012 [-0,0047; +0,0074]	-0,0033 [-0,0150; +0,0070]	+0,0453 [-0,0069; +0,1181]	-0,0017 [-0,0044; +0,0006]
Gợi ý văn bản: Giai đoạn 1 mới trừ cũ	+0,0010 [-0,0040; +0,0062]	-0,0015 [-0,0095; +0,0068]	+0,0232 [-0,0151; +0,0700]	-0,0007 [-0,0026; +0,0013]
Gợi ý văn bản trừ không gợi ý, Giai đoạn 1 mới	-0,0008 [-0,0063; +0,0047]	+0,0021 [-0,0067; +0,0122]	-0,0088 [-0,0805; +0,0539]	-0,0003 [-0,0026; +0,0022]

Thay Giai đoạn 1 bằng mô hình huấn luyện với hàm mất mát phân cấp, vốn có điểm hiện diện được hiệu chuẩn tốt hơn giữa các nhãn, không cải thiện Giai đoạn 2 qua kênh token mềm lẫn kênh gợi ý văn bản.

3.7. Kiểm tra độ tin cậy của lời giải thích

Bản đồ giải thích của Giai đoạn 2 được tính bằng lan truyền chú ý có trọng số gradient theo Chefer và cộng sự [24] trên hệ thống A, 300 nghiên cứu kiểm tra. Hai phép kiểm tra được chạy trước khi xuất bất kỳ bản đồ nào và có quyền hủy cả lần chạy. Phép kiểm tra thứ nhất thay ảnh của nghiên cứu bằng ảnh của nghiên cứu khác và đo mức tăng log-likelihood âm của báo cáo tham chiếu. Phép kiểm tra thứ hai khởi tạo lại ngẫu nhiên

các lớp của mô hình ngôn ngữ từ lớp cuối trở xuống theo Adebayo và cộng sự [25] và đo tương quan hạng Spearman giữa bản đồ mới và bản đồ gốc.

Bảng 3.11. *Kiểm tra độ tin cậy lời giải thích trên hệ thống A (tập kiểm tra, số liệu ghi nhận)*

Phép kiểm tra	Số mẫu	Kết quả
Thay ảnh bằng ảnh nghiên cứu khác, tăng log-likelihood âm	100	+0,2160 [+0,1860; +0,2468], 94% nghiên cứu xấu đi
Khởi tạo lại 1, 2, 4, 8, 16, 34 lớp, tương quan Spearman	1	0,986; 0,981; 0,893; 0,769; 0,694; 0,295
Tỉ lệ câu gán được nhãn bằng từ điển	1.728 câu	0,6846

Cả hai phép kiểm tra đều đạt: mô hình dùng đúng ảnh của nghiên cứu, và bản đồ suy biến dần khi trọng số bị phá. Điểm đầu tiên của đường suy biến (0,986 sau khi khởi tạo lại một lớp) cho thấy phương pháp ít nhạy với phần trên cùng của mô hình, và cần được nêu rõ. Từ điển gán nhãn câu là danh sách từ khóa, không phải bộ gán nhãn lâm sàng.

3.8. So sánh với công trình liên quan

Bảng 3.12. *Kết quả sinh báo cáo trên tập kiểm tra MIMIC-CXR của các công trình và của đề tài*

Công trình	BLEU-1	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTScore	CE F1
R2Gen [5]	0,353	0,103	0,142	0,277	không báo cáo	không báo cáo	0,276
METransformer [21]	0,386	0,124	0,152	0,291	0,362	không báo cáo	không báo cáo
PromptMRG [22]	0,398	0,112	0,157	0,268	không báo cáo	không báo cáo	0,476
META-CXR gốc [4]	không báo cáo	0,102	0,173	0,280	0,291	0,426	không báo cáo
MedGemma không tinh chỉnh	0,277	0,056	0,136	0,200	0,079	0,126 (co giãn)	không có
Hệ thống A (ảnh gốc, tinh chỉnh)	0,164	0,045	0,096	0,191	0,144	0,137 (co giãn)	không có
Hệ thống C (kết hợp, tinh chỉnh)	0,092	0,028	0,080	0,173	0,195	0,065 (co giãn)	không có

Số của các công trình khác lấy trực tiếp từ bảng kết quả trong chính công trình đó; số của META-CXR gốc lấy từ trang mã nguồn của nhóm tác giả. CE F1: F1 lâm sàng tính bằng bộ gán nhãn trên báo cáo sinh ra, đề tài không có.

Bảng 3.13. *Khác biệt giao thức cần lưu ý khi đọc bảng so sánh*

Công trình	Tập kiểm tra	Ghi chú
R2Gen	3.269 báo cáo, phân chia chính thức	coco-caption; beam 3; trung bình 5 lần chạy; CE bằng CheXpert
METransformer	3.269 mẫu, phân chia như R2Gen	Không nêu tên bộ công cụ trong phần trích xuất
PromptMRG	3.858 mẫu theo tiền xử lý của R2Gen	CE bằng CheXbert, 14 nhãn, trung bình theo mẫu
META-CXR gốc	Không nêu trong trang mã nguồn	Chưa rõ BERTScore có co giãn hay không; cần đối chiếu bản đầy đủ

Công trình	Tập kiểm tra	Ghi chú
Đề tài	2.772 nghiên cứu, tập con của phân chia chính thức	coco-caption; tham lam; một lần chạy; chỉ phần FINDINGS

Trên các độ đo được tính cùng giao thức, hệ thống của đề tài thấp hơn các công trình chuyên sinh báo cáo đã công bố. Ba khác biệt giới hạn phép so sánh: tập kiểm tra của đề tài là tập con 2.772 nghiên cứu thay vì toàn bộ 3.269; các công trình kia dùng beam search và trung bình nhiều lần chạy; và báo cáo sinh ra của đề tài ngắn hơn đáng kể so với tham chiếu, làm giảm trực tiếp BLEU và METEOR. Báo cáo kỹ thuật của MedGemma [9] chỉ công bố RadGraph F1 29,5 trên tập 306 ca với cả hai phần FINDINGS và IMPRESSION, là độ đo và tập đánh giá khác, nên không được đặt vào bảng trên.

CHƯƠNG 4. SO SÁNH VỚI BÀI BÁO GỐC META-CXR

4.1. Khác biệt về kiến trúc và quy trình

Đề tài kế thừa mã nguồn công bố cùng bài báo META-CXR [4] và thay đổi nhiều thành phần. Bảng dưới đây liệt kê các khác biệt chính. Thông tin về bài báo gốc lấy từ trang mã nguồn của nhóm tác giả và từ chính mã nguồn tham chiếu; bản toàn văn trên IEEE Xplore không truy cập được bằng công cụ tự động trong quá trình thực hiện, nên các mục không nêu trên trang mã nguồn được ghi là không nêu.

Bảng 4.1. *Khác biệt giữa bài báo gốc và đề tài*

Khía cạnh	META-CXR gốc	Đề tài
Bộ mã hóa ảnh	ResNet-50, ViT, Swin	BioViL-T (ResNet-50) và PubMedCLIP (ViT-B/32); tắt Swin
Mô hình ngôn ngữ	Vicuna-7B với LoRA theo mã nguồn tham chiếu	MedGemma 1.5 4B, QLoRA NF4
Kênh thị giác vào mô hình ngôn ngữ	Token mềm Q-Former thay cho ảnh	Tháp ảnh MedGemma, thêm token mềm và gợi ý ở hệ thống C
Mục tiêu căn chỉnh Q-Former	Bị vô hiệu trong mã nguồn tham chiếu	Tắt sau bốn lần đo ở mức ngẫu nhiên
Đơn vị lấy mẫu	Ảnh, trong mã nguồn kế thừa ban đầu	Nghiên cứu, một ảnh chính và tối đa một ảnh phụ
Nhãn để trống	Điền âm tính, trong mã nguồn kế thừa ban đầu	Che theo từng ô, không coi là âm tính
Cổng nhắc tới	Không có	Có, học từ các ô để trống
Hợp nhất nhiều góc nhìn	Không có	Có, theo từng bộ mã hóa
Cách chấm phân loại	Ba lớp P/N/U, 13 bệnh lý và No Finding	Hiện diện theo nghiên cứu, điểm biên; kèm ba lớp P/N/U để đối chiếu
Chọn ngưỡng	Không nêu	Hiệu chuẩn trên tập kiểm định, quy tắc bình nguyên

4.2. Đặt kết quả cạnh nhau

Bảng 4.2. *Phân loại ba lớp P/N/U trên các ô được nhắc tới (tập kiểm tra)*

Hệ thống	Precision TB	Recall TB	F1 TB	F1 âm tính	F1 dương tính	F1 không chắc
META-CXR gốc (trang mã nguồn)	0,87	0,78	0,73	không nêu	không nêu	không nêu
Đề tài, argmax trên phân bố q	0,4775	0,5129	0,4939	0,7090	0,7698	0,0030
Baseline luôn dương tính	0,2216	0,3333	0,2662	0,0000	0,7987	0,0000
Baseline lớp đa số theo từng nhãn	0,6731	0,5427	0,5702	0,4912	0,8359	0,3837

TB: trung bình theo ba lớp, precision không xác định tính bằng 0. Đề tài tính trên 10.796 ô được nhắc tới. Trang mã nguồn của bài báo gốc không nêu cách lấy trung bình.

Lớp không chắc chắn của đề tài có F1 0,0030 vì mô hình được huấn luyện với chính sách bỏ qua nhãn không chắc chắn, nên đầu ra của lớp này không bao giờ nhận tín hiệu học. Hệ quả là theo cách chấm ba lớp, baseline lớp đa số đạt F1 trung bình 0,5702, cao

hơn mô hình (0,4939); con số này phản ánh chính sách huấn luyện chứ không phản ánh khả năng phân cực. Khi bỏ lớp không chắc chắn cho khớp chính sách huấn luyện (Mục 2.3), F1 dương tính trung bình theo nhãn của mô hình là 0,8864, so với 0,8397 của baseline luôn dương tính và 0,8200 của baseline lớp đa số. Vì bài báo gốc không nêu cách xử lý lớp không chắc chắn và cách lấy trung bình, cả hai phép chấm này đều không so trực tiếp được với con số 0,73; chúng được trình bày để cho thấy các con số P/N/U cần baseline tầm thường đi kèm mới có ý nghĩa.

Bảng 4.3. *Sinh báo cáo: bài báo gốc và đề tài*

Hệ thống	BLEU-4	METEOR	ROUGE-L	CIDEr	BERTScore
META-CXR gốc (trang mã nguồn)	0,102	0,173	0,280	0,291	0,426 (chưa rõ co giãn)
Hệ thống A (ảnh gốc, tinh chỉnh)	0,045	0,096	0,191	0,144	0,137 co giãn; 0,854 thô
Hệ thống C (kết hợp, tinh chỉnh)	0,028	0,080	0,173	0,195	0,065 co giãn; 0,842 thô

Số của đề tài theo giao thức chuẩn trên tập kiểm tra. Bài báo gốc không nêu tập kiểm tra, bộ công cụ và mô hình BERTScore trên trang mã nguồn.

4.3. Các thay đổi và bằng chứng đo được

Không phải mọi thay đổi so với bài báo gốc đều là cải tiến có bằng chứng về chỉ số. Nhiều thay đổi là sửa lỗi tính đúng đắn, chẳng hạn cách xử lý nhãn trống hay điều kiện dừng sinh, mà giá trị của chúng nằm ở việc làm cho phép đo có nghĩa chứ không ở việc làm tăng một con số. Bảng dưới đây phân biệt rõ ba nhóm: có cải thiện đo được, không cải thiện, và sửa lỗi không có đối chứng chỉ số.

Bảng 4.4. *Tổng hợp tác động của các thay đổi*

Thay đổi	Tác động đo được	Mục
Mở khóa phần trên bộ mã hóa	**AUROC macro +0,0201 [+0,0139; +0,0266]**	2.6.1
Dùng cổng nhắc tới khi chấm	**AUROC macro +0,0616 [+0,0527; +0,0706]**	2.6.1
Hạ số ca dương tối thiểu khi hiệu chuẩn	**F1 macro +0,0181 [+0,0140; +0,0227], đổi precision lấy recall**	2.6.1
Sửa điều kiện dừng sinh	**Token sau mã kết thúc từ 78% về 0%**	3.5
Chọn ngưỡng theo bình nguyên	Không thay đổi F1 có ý nghĩa	2.6.1
Mở khóa sâu hơn	Không cải thiện khả năng phân biệt	2.6.1
Hàm mất mát phân cấp	Cải thiện hiệu chuẩn giữa các nhãn, không cải thiện phân biệt, không có lợi ở Giai đoạn 2	2.6.1, 3.6
Hàm mất mát giải thích	Không cải thiện, tăng 15,5% thời gian huấn luyện	2.6.2
Mục tiêu căn chỉnh Q-Former	Ở mức ngẫu nhiên trong bốn lần đo	2.6.2
Huấn luyện thêm epoch	Không cải thiện trên tập kiểm tra	2.6.2
Gợi ý văn bản và token phát hiện	Không cải thiện sinh báo cáo	3.6
Che nhãn trống, cách chấm hiện diện	Sửa lỗi tính đúng đắn; loại bỏ baseline tầm thường đạt F1 cao	2.3

CHƯƠNG 5. THẢO LUẬN VÀ HẠN CHẾ

5.1. Thảo luận

Kết quả Giai đoạn 1 cho thấy mô hình đạt khả năng phân biệt ở mức trung bình trên câu hỏi hiện diện bệnh lý và thấp hơn một đường cơ sở CNN chuyên phân loại trên cùng chính sách nhãn. Trong các lựa chọn huấn luyện đã thử, chỉ việc mở khóa phần trên của bộ mã hóa cải thiện khả năng phân biệt; các hàm mất mát bổ sung hoặc không tạo khác biệt, hoặc chỉ thay đổi hiệu chuẩn và điểm vận hành. Một bài học phương pháp quan trọng là cách chấm: cùng một tệp dự đoán cho F1 gần 0,9 hoặc khoảng 0,35 tùy cách diễn giải ô nhãn trống, và chỉ cách chấm có baseline tầm thường bằng 0 mới phản ánh kỹ năng thực.

Trên tập kiểm tra, so với MedGemma không tinh chỉnh, hệ thống A có CIDEr cao hơn có ý nghĩa (+0,0647), METEOR thấp hơn có ý nghĩa (-0,0274) và BERTScore thô không khác biệt có ý nghĩa (+0,0019); hệ thống C so với hệ thống A có CIDEr cao hơn có ý nghĩa (+0,0512) và BERTScore thô thấp hơn có ý nghĩa (-0,0121). Kết quả này cần được đọc cùng hai điều kiện: hệ thống A chỉ hoàn thành 0,86 epoch, và báo cáo sinh ra của cả ba hệ thống đều ngắn hơn đáng kể so với báo cáo tham chiếu.

Kết quả Giai đoạn 2 cho thấy mô hình ngôn ngữ thị giác không khai thác các kênh thông tin có cấu trúc từ Giai đoạn 1. Gợi ý văn bản, kể cả khi precision được nâng lên đáng kể, không cải thiện báo cáo; token học được mang giá trị liên tục cũng không, và các phép can thiệp phá hủy thông tin trong token không làm đổi đầu ra. Giải thích phù hợp nhất là tháp ảnh của MedGemma đã mang phần lớn thông tin mà các kênh này cung cấp, trong khi token mềm của Q-Former là một phép đọc cố định chưa được huấn luyện căn chỉnh. Đây là một kết quả âm có đối chứng chặt, và nó trả lời trực tiếp câu hỏi thiết kế ban đầu của đề tài.

5.2. Hạn chế

Thứ nhất, mỗi cấu hình chỉ được huấn luyện với một hạt giống, nên không có ước lượng biến thiên giữa các lần khởi tạo; khoảng tin cậy trong tài liệu phản ánh biến thiên do mẫu kiểm tra chứ không phải biến thiên do huấn luyện. Thứ hai, hệ thống A chỉ hoàn thành 0,86 epoch và không có bước chọn checkpoint. Thứ ba, đề tài không có độ đo lâm sàng đã kiểm chứng như F1 dựa trên CheXbert hay RadGraph, là các độ đo mà nhiều

công trình sinh báo cáo gần đây dùng làm kết quả chính. Thứ tư, báo cáo sinh ra ngắn hơn đáng kể so với báo cáo tham chiếu, và các mô hình tinh chỉnh có xu hướng sụp về một số câu mẫu rất ngắn trên tập kiểm tra, làm giảm các độ đo dựa trên độ phủ; nguyên nhân huấn luyện của hiện tượng này chưa được xác định. Thứ năm, tập kiểm tra Giai đoạn 2 là tập con 2.772 nghiên cứu, và khoảng 6% báo cáo đích dùng khi huấn luyện là các đoạn một dòng chủ yếu mô tả kỹ thuật chụp. Thứ sáu, các thí nghiệm cắt bỏ trên kênh gợi ý dùng ngân sách huấn luyện 10.000 nghiên cứu, loại trừ được chế độ đó chứ không loại trừ một lần huấn luyện đầy đủ. Cuối cùng, số liệu của bài báo gốc được lấy từ trang mã nguồn của nhóm tác giả và cần được đối chiếu với bản toàn văn trên IEEE Access trước khi dùng trong bản nộp chính thức.

TÀI LIỆU THAM KHẢO

[1] A. Johnson, M. Lungren, Y. Peng, Z. Lu, R. Mark, S. Berkowitz, and S. Horng, "MIMIC-CXR-JPG, chest radiographs with structured labels," version 2.1.0, PhysioNet, 2024, doi: 10.13026/jsn5-t979.

[2] A. E. W. Johnson, T. J. Pollard, S. J. Berkowitz, N. R. Greenbaum, M. P. Lungren, C.-Y. Deng, R. G. Mark, and S. Horng, "MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports," Scientific Data, vol. 6, no. 1, p. 317, 2019.

[3] J. Irvin et al., "CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison," in Proc. AAAI Conference on Artificial Intelligence, vol. 33, 2019.

[4] D. Edirisinghe, W. Nimalsiri, M. Hennayake, D. Meedeniya, and G. Lim, "Chest X-ray report generation using abnormality guided vision language model," IEEE Access, vol. 13, pp. 157651-157673, 2025, doi: 10.1109/ACCESS.2025.3606961.

[5] Z. Chen, Y. Song, T.-H. Chang, and X. Wan, "Generating radiology reports via memory-driven Transformer," in Proc. Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020.

[6] S. Bannur et al., "Learning to exploit temporal structure for biomedical vision-language processing," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023.

[7] S. Eslami, C. Meinel, and G. de Melo, "PubMedCLIP: How much does CLIP benefit visual question answering in the medical domain?," in Findings of the Association for Computational Linguistics: EACL, 2023.

[8] J. Li, D. Li, S. Savarese, and S. Hoi, "BLIP-2: Bootstrapping language-image pre-training with frozen image encoders and large language models," in Proc. International Conference on Machine Learning (ICML), 2023.

[9] L. Yang et al., "MedGemma technical report," arXiv:2507.05201, 2025.

[10] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient finetuning of quantized LLMs," in Advances in Neural Information Processing Systems (NeurIPS), 2023.

[11] E. J. Hu et al., "LoRA: Low-rank adaptation of large language models," in Proc. International Conference on Learning Representations (ICLR), 2022.

[12] B. Efron and R. J. Tibshirani, An Introduction to the Bootstrap. New York: Chapman and Hall, 1993.

[13] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, "BLEU: A method for automatic evaluation of machine translation," in Proc. Annual Meeting of the Association for Computational Linguistics (ACL), 2002.

[14] S. Banerjee and A. Lavie, "METEOR: An automatic metric for MT evaluation with improved correlation with human judgments," in Proc. ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization, 2005.

[15] C.-Y. Lin, "ROUGE: A package for automatic evaluation of summaries," in Text Summarization Branches Out, 2004.

[16] R. Vedantam, C. L. Zitnick, and D. Parikh, "CIDEr: Consensus-based image description evaluation," in Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015.

[17] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT," in Proc. International Conference on Learning Representations (ICLR), 2020.

[18] X. Chen, H. Fang, T.-Y. Lin, R. Vedantam, S. Gupta, P. Dollar, and C. L. Zitnick, "Microsoft COCO captions: Data collection and evaluation server," arXiv:1504.00325, 2015.

[19] Y. Liu et al., "RoBERTa: A robustly optimized BERT pretraining approach," arXiv:1907.11692, 2019.

[20] L. Seyyed-Kalantari, G. Liu, M. McDermott, I. Y. Chen, and M. Ghassemi, "CheXclusion: Fairness gaps in deep chest X-ray classifiers," in Proc. Pacific Symposium on Biocomputing (PSB), 2021, arXiv:2003.00827.

[21] Z. Wang, L. Liu, L. Wang, and L. Zhou, "METransformer: Radiology report generation by Transformer with multiple learnable expert tokens," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023, arXiv:2304.02211.

[22] H. Jin, H. Che, Y. Lin, and H. Chen, "PromptMRG: Diagnosis-driven prompts for medical report generation," in Proc. AAAI Conference on Artificial Intelligence, 2024, arXiv:2308.12604.

[23] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in Proc. IEEE International Conference on Computer Vision (ICCV), 2017.

[24] H. Chefer, S. Gur, and L. Wolf, "Transformer interpretability beyond attention visualization," in Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021.

[25] J. Adebayo, J. Gilmer, M. Muelly, I. Goodfellow, M. Hardt, and B. Kim, "Sanity checks for saliency maps," in Advances in Neural Information Processing Systems (NeurIPS), 2018.